

Universidad Nacional de Ingeniería

Facultad de Ingeniería Eléctrica y Electrónica

Proyecto de Tesis

Ingeniería Electrónica

**Detección de Lenguaje Ofensivo en Redes Sociales
empleando Modelos Transformers de Deep Learning**

Autor:

Rosales Aliaga Fabio

Tutor:

MSc. MBA. Ing. René Mitma Ramírez

Lima - Perú
Junio - 2025

*A mis padres y hermanos,
por su amor, apoyo incondicional y confianza
en cada paso de este camino académico.*

Fabio Rosales Aliaga

Agradecimientos

Quiero expresar mi más profundo agradecimiento a todas las personas que me han acompañado a lo largo de este proyecto y durante mi formación académica.

A mi familia, por su esfuerzo diario y el ejemplo de responsabilidad que me han inculcado.

A mi asesor, el ingeniero René Mitma Ramírez, por su orientación, paciencia y por compartir su conocimiento de forma tan generosa durante el desarrollo de este trabajo.

A mis amigos y compañeros, por su apoyo, palabras de aliento y por los momentos compartidos que hicieron más llevadero este camino.

Finalmente, agradezco a todas las personas que, de una u otra forma, contribuyeron con este logro. Cada gesto, por más pequeño que haya sido, significó mucho para mí.

Índice general

	Página
Lista de Tablas	5
Lista de Figuras	6
Lista de Acrónimos	8
Resumen	9
1. Introducción	11
1.1. Contexto	11
1.2. Descripción del Problema	11
1.3. Solución Tecnológica	11
1.4. Referencias a tomar en cuenta	12
1.5. Estado del Arte	13
2. Análisis del Panorama Actual del Lenguaje Ofensivo en Internet	14
2.1. Estadísticas Actuales	14
2.2. Impacto del Lenguaje Ofensivo	17
2.3. Ejemplos de incidentes notorios con comentarios ofensivos	19
2.4. Mercado Global	22
3. Mercado Objetivo	26
3.1. Identificación del Mercado Objetivo	26
3.2. Identificación del Mercado Objetivo	26
3.3. Elección del Mercado Objetivo	27
3.4. Panorama Nacional en Medios Digitales	27
4. Oferta Tecnológica Mundial	28
4.1. Tecnologías Utilizadas en la Detección de Lenguaje Ofensivo	28
4.2. Precio del Mercado	30
4.3. Limitaciones de la Oferta Actual	31
5. Flujo de Ingresos Proyectados	32
6. OffendES y su aplicación en el proyecto	35
6.1. Características del corpus OffendES	35

7. Modelos Transformers y su aplicación en el proyecto	38
7.1. Ventajas del Modelo	38
7.2. Proceso en el Proyecto	39
8. Diseño de los datos de entrada	40
9. Diseño y Despliegue del modelo de clasificación	43
9.1. Diseño del Modelo	43
9.2. Despliegue del Modelo	46
10. Evaluación Económica Financiera	49
10.1. Estimación del Alcance	49
10.2. Costos de Operación	49
10.3. Gastos Administrativos y Comerciales	52
10.4. Gastos Financieros	53
10.5. Costos Totales	53
10.6. Proyección a la inversión	54
10.7. Proyección de los Ingresos	57
10.8. Evaluación Financiera	58
11. Normas Técnicas	66
11.1. Normas de Desarrollo y Documentación de Software	66
11.2. Normas sobre gestión de datos	66
11.3. Normas sobre modelos de IA	66
12. Conclusiones y Trabajos Futuros	67
12.1. Conclusiones	67
A. Anexos	69
A.1. Funciones para Datos Tokenizados	69
A.2. Muestra de un Dato Tokenizado	70
A.3. Funciones para el Modelo	71
A.4. Ejemplos de textos clasificados	73
Referencias	77

Lista de Tablas

2.1. Tipos de acoso experimentados por jugadores en línea Fuente: [1]	17
2.2. Tipo de videojuegos con los mayores abusos Fuente: [1]	17
2.3. Participación en ingresos del mercado de servicios de moderación de contenido (2023) [Elaboración Propia]	24
2.4. CAGR estimado en servicios de moderación de contenido (2024–2032) [Elaboración Propia]	24
4.1. Servicios de moderación de contenido disponibles en distintas plataformas (elaboración propia a partir de información pública de los sitios oficiales) [Elaboración Propia]	31
5.1. Estimaciones por Servicio [Elaboración Propia]	32
5.2. Proyección de ingresos para un cliente [Elaboración Propia]	33
9.1. Análisis de métricas del modelo [Elaboración Propia]	46
10.8. Costos de Herramientas de Servicio [Elaboración Propia]	52
10.9. Costos Indirectos [Elaboración Propia]	52
10.10. Gastos Administrativos [Elaboración Propia]	52
10.11. Gastos de Venta [Elaboración Propia]	53
10.12. Gastos Financieros [Elaboración Propia]	53
10.13. Costo Total del Servicio [Elaboración Propia]	54
10.14. Mobiliario de Administración [Elaboración Propia]	54
10.15. Mobiliario de Desarrollo [Elaboración Propia]	54
10.16. Mobiliario de Ventas [Elaboración Propia]	55
10.17. Depreciación de Activos tangibles [Elaboración Propia]	55
10.18. Plan de Inversión [Elaboración Propia]	56
10.19. Balance de Apertura [Elaboración Propia]	57
10.20. Proyección de Ingresos [Elaboración Propia]	58
10.21. Ventas al contado y al crédito [Elaboración Propia]	58
10.22. Determinación de Ingresos Efectivo [Elaboración Propia]	58
10.23. Estado de Resultados [Elaboración Propia]	59
10.24. Presupuesto Caja [Elaboración Propia]	60
10.25. Balance General Proyectado [Elaboración Propia]	61
10.26. Flujo Neto de Efectivo [Elaboración Propia]	62
10.27. Costo de Capital [Elaboración Propia]	63
10.28. Valor Neto Actual y Periodo de Recuperación [Elaboración Propia]	64
10.29. Tasa interna de retorno [Elaboración Propia]	64
10.30. Índice de Rentabilidad [Elaboración Propia]	64

Lista de Acrónimos

API	Application Programming Interface. 28, 31
BERT	Bidirectional Encoder Representations from Transformers. 38, 43
CAGR	Tasa de Crecimiento Anual Compuesta. 5, 22–24, 32, 33
IA	Inteligencia Artificial. 22
LSTM	Memoria a Corto Plazo. 38
ML	Machine Learning. 22
MOBA	Multiplayer Online Battle Arena. 17
MTurk	Amazon Mechanical Turk. 35
MVP	Producto Mínimo Viable. 40
PLN	Procesamiento del Lenguaje Natural. 12, 28, 35, 38
PYME	Pequeña y Mediana Empresa. 22, 24
RNN	Redes Neuronales Recurrentes. 38

Resumen

Al día de hoy, las redes sociales han transformado la manera en que las personas se comunican e interactúan entre sí, además de ser un espacio libre para compartir información, noticias, fotos y videos; sin embargo, la libre expresión y falta de censura, esto sumado a la sensación de anonimato por parte de los usuarios, ha resultado en un aumento de conductas negativas y perjudiciales para el internauta, tales como el acoso, la discriminación y la intimidación. Por ello, el presente proyecto propone el diseño y desarrollo de un sistema de detección automática de lenguaje ofensivo que pueda detectar dichos mensajes de odio para proteger al usuario.

El objetivo principal es ofrecer una solución precisa, adaptable y funcional en tiempo real, dirigida inicialmente a medios de comunicación digitales que enfrentan limitaciones para abrir sus espacios de comentarios por temor a contenidos ofensivos. El sistema podrá integrarse como servicio externo o mediante API, permitiendo filtrar contenido antes de su publicación pública, incluso en escenarios de transmisión en vivo. El proyecto considera el diseño del pipeline de clasificación, la preparación y limpieza del dataset, el entrenamiento y evaluación del modelo, así como una proyección de viabilidad económica, escalabilidad técnica y análisis de mercado.

Como resultado, se espera contribuir al desarrollo de herramientas inclusivas y accesibles para la moderación automática del lenguaje ofensivo en español, promoviendo entornos digitales más seguros y abiertos a la participación constructiva del público.

Palabras clave: Lenguaje ofensivo, procesamiento del lenguaje natural, moderación automática de contenido, transformers

Abstract

Today, social media has transformed the way people communicate and interact with each other, offering a free space for sharing information, news, photos, and videos. However, free expression and lack of censorship, coupled with users' sense of anonymity, have resulted in an increase in negative and harmful behaviors, such as harassment, discrimination, and bullying, for Internet users. Therefore, this project proposes the design and development of an automatic offensive language detection system that can detect such hate speech and protect users.

The main objective is to offer an accurate, adaptable, and functional real-time solution, initially aimed at digital media outlets that face limitations in opening their comment spaces for fear of offensive content. The system can be integrated as an external service or through an API, allowing content to be filtered before public publication, even in live streaming scenarios. The project considers the design of the classification pipeline, dataset preparation and cleaning, model training and evaluation, as well as a projection of economic viability, technical scalability, and market analysis.

As a result, we hope to contribute to the development of inclusive and accessible tools for the automatic moderation of offensive language in Spanish, promoting safer digital environments that are open to constructive public participation.

Keywords: Offensive language, natural language processing, automatic content moderation, transformers

Capítulo 1

Introducción

1.1. Contexto

En la última década, el crecimiento explosivo del internet y las plataformas digitales ha transformado la forma en que las personas se comunican, comparten ideas y participan en comunidades. Sin embargo, este avance ha traído consigo un problema creciente: el uso del lenguaje ofensivo, el discurso de odio y la toxicidad en línea.

Diversos estudios han demostrado que el lenguaje ofensivo ha aumentado significativamente en redes sociales como X (antes Twitter), Facebook y TikTok, así como en plataformas de videojuegos y streaming como Twitch, Kick. Por ejemplo, una investigación reciente de la Universidad del Sur de California reveló un incremento del 50 % en el discurso de odio en X tras la modificación de sus políticas de moderación [2]. De forma paralela, más del 90 % de los gamers ha experimentado o presenciado acoso en línea, según un informe de Preply [1].

1.2. Descripción del Problema

En los espacios digitales actuales, es cada vez más común encontrar mensajes con un tono hostil o agresivo. Este tipo de interacción no solo afecta el bienestar emocional de los usuarios —sobre todo en el caso de mujeres y jóvenes—, sino que también perjudica la calidad del debate y la participación en línea. El lenguaje ofensivo, cuando no se modera adecuadamente, tiende a reforzar dinámicas de exclusión y polarización, e incluso puede derivar en formas de violencia simbólica o verbal.

Aunque ya existen sistemas de moderación automática, su desempeño sigue siendo limitado. Estos mecanismos a menudo cometen errores, pasan por alto ciertos matices del lenguaje o no logran adaptarse a contextos culturales distintos. Esto ocurre especialmente en entornos donde el idioma predominante no es el inglés, como en el caso del español. Ante esta situación, se vuelve imprescindible contar con herramientas que no solo sean más precisas, sino que también estén alineadas con las particularidades lingüísticas y sociales del público hispanohablante.

1.3. Solución Tecnológica

La solución tecnológica propuesta consiste en el desarrollo de un modelo de aprendizaje automático basado en arquitecturas de transformers, específicamente entrenado para

detectar lenguaje ofensivo en

textos en español. Para ello, utilizamos el dataset OffendES [3], un corpus anotado en español que distingue entre lenguaje ofensivo y no ofensivo, el cual permite abordar el problema como una tarea de clasificación.

1.4. Referencias a tomar en cuenta

1.4.1. Referencia 1: Detección de ciberacoso en internet y redes sociales mediante técnicas de procesamiento de lenguaje natural

En este trabajo de fin de grado se aborda la problemática del ciberacoso en entornos digitales, para lo cual la autora propone un enfoque basado en técnicas de Procesamiento del Lenguaje Natural (PLN) para su detección. El trabajo busca detectar comentarios ofensivos de idioma español e inglés orientados al feminismo y comentarios machistas, utilizando técnicas más modernas como modelos preentrenados que han dejado atrás a métodos más clásicos. Entre los factores de aporte podemos rescatar:

- **Factor de Aporte 1:** El uso de datasets públicos como opción a la elaboración manual de estos, sin embargo, esto se hizo solo para el idioma inglés y para el idioma español se elaboró uno propio recolectando tweets de la red social X.
- **Factor de Aporte 2:** Utiliza modelos más modernos como los modelos Transformers y modelos híbridos que complementan estos primeros con la adición de metadatos lingüísticos.

1.4.2. Referencia 2: Identificación de lenguaje ofensivo en textos en español utilizando técnicas de aprendizaje supervisado y lexicones

Este trabajo de investigación, al igual que el presente estudio, aborda la problemática del incremento de expresiones ofensivas en entornos digitales, así como la escasez de herramientas eficaces para abordarlo en lengua española. Su propósito principal fue desarrollar un sistema para detectar lenguaje ofensivo dirigido, con énfasis en contenidos relacionados con la comunidad LGBTIQ+, utilizando seis enfoques distintos de aprendizaje supervisado.

Entre los elementos más relevantes de esta tesis, destacan los siguientes:

- **Factor de Aporte 3:** A partir de técnicas de procesamiento del lenguaje natural, se elaboró un lexicón especializado enfocado en identificar términos ofensivos dirigidos a personas LGBTIQ+. Este recurso fue construido a partir de comentarios recopilados en la plataforma Twitter (hoy conocida como X), con el objetivo de ofrecer una alternativa más específica y contextualizada frente a otros lexicones genéricos ya existentes.

- **Factor de Aporte 4:** El estudio logró fortalecer sus resultados combinando modelos supervisados con el lexicón especializado, lo que permitió mejorar la precisión en la identificación de lenguaje ofensivo en comparación con enfoques que utilizan únicamente una de estas técnicas.

1.5. Estado del Arte

1.5.1. Referencia 1: Detección de ciberacoso en internet y redes sociales mediante técnicas de procesamiento de lenguaje natural

Este trabajo ha servido como base fundamental, con grandes puntos de vista y aspectos claves para la elaboración de la presente tesis. Por lo que se busca reforzar los siguientes factores:

- **Innovación del Factor de Aporte 1:** A diferencia del Trabajo de Fin de Grado, que recolectó tweets únicamente de Twitter, nosotros utilizaremos el corpus OffendES, que presenta comentarios de más plataformas [3].
- **Innovación del Factor de Aporte 2:** Si bien, también se usarán modelos pre-entrenados, el enfoque que se dará es uno con orientación práctica, dándole una utilidad a las predicciones obtenidas.

1.5.2. Referencia 2: Identificación de lenguaje ofensivo en textos en español utilizando técnicas de aprendizaje supervisado y lexicones

Aunque esta tesis representa un aporte fundamental para el desarrollo de herramientas de detección de lenguaje ofensivo en español, el presente trabajo introduce nuevos enfoques y ampliaciones relevantes:

- **Innovación del Factor de Aporte 3:** Mientras que la tesis se enfoca en mensajes dirigidos exclusivamente a la comunidad LGBTIQ+, esta investigación propone una aproximación más amplia donde el lenguaje ofensivo es frecuente, especialmente hacia adolescentes, mujeres y minorías.
- **Innovación del Factor de Aporte 4:** En cuanto a la arquitectura de detección, se busca incorporar modelos más modernos y robustos, como los Transformers pre-entrenados en español, que ofrecen mayor capacidad de comprensión semántica que los métodos clásicos utilizados en la tesis mencionada.

Capítulo 2

Análisis del Panorama Actual del Lenguaje Ofensivo en Internet

2.1. Estadísticas Actuales

Un estudio publicado este año analiza el desarrollo de la agresividad en la plataforma X (anteriormente conocida como Twitter) a partir de su adquisición por Elon Musk, quien implementó una política de moderación de contenido más flexible. Esta decisión podría estar relacionada con el aumento de los discursos de odio en la plataforma [2].

El artículo fue publicado el 12 de febrero de 2025 y presenta un análisis que abarca desde principios de 2022 hasta el 9 de junio de 2023, utilizando como base publicaciones en inglés extraídas de la plataforma X. El estudio revela un incremento considerable de al menos un 50 % en los mensajes con contenido de odio tras la compra de la plataforma por parte de Elon Musk. Asimismo, se identificó una mayor interacción con este tipo de publicaciones: el promedio de "me gusta"^{en} mensajes catalogados como discurso de odio creció en un 70 %, lo que sugiere no solo una mayor exposición sino también una preocupante aceptación por parte de los usuarios.

El análisis se apoya en distintos gráficos estadísticos que refuerzan sus conclusiones. Por ejemplo, la Figura 2.1 representa la variación semanal del número de publicaciones con lenguaje de odio antes y después del cambio de administración en la red. El gráfico muestra una tendencia al alza, con un punto crítico en abril de 2023. Este repunte se vincula con la aparición de una mujer transgénero en una campaña publicitaria, hecho que desató una ola de reacciones hostiles en línea y contribuyó a intensificar el volumen de mensajes ofensivos en la plataforma.

Figura 2.1: Publicaciones de odio con el tiempo. Fuente: [2]

Por su parte, la Figura 2.2 ilustra cómo aumentó la participación de los usuarios en publicaciones clasificadas como discursos de odio. Específicamente, se evidencia un incremento notable en el promedio de "me gusta" que reciben estos tuits, con un aumento del 70 % tras los cambios en la política de moderación. Este dato sugiere no solo una mayor circulación de contenido dañino, sino también una creciente validación o aceptación por parte de los usuarios.

Figura 2.2: Promedio de me gusta y republicaciones de (a) publicaciones de odio y (b) publicaciones de referencia antes y después de la adquisición de Musk. Fuente: [2].

Finalmente, la Figura 2.3 revela cuáles categorías de odio aumentaron más visiblemente, revelando tendencias específicas en la expresión de agresividad. Esta figura es particularmente útil para identificar los grupos más afectados por la flexibilización en la moderación del contenido.

Figura 2.3: Aumento de los discursos de odio para diferentes dimensiones del odio. Las líneas negras representan errores estándar. Fuente: [2].

Alejándonos por un momento del entorno de las redes sociales, un estudio realizado por Preply los días 21 y 22 de enero de 2022 encuestó a 1,409 personas que juegan videojuegos, de las cuales el 58 % se identificó como hombre y el 42 % como mujer, con una edad promedio de 36 años [1]. Esta encuesta arrojó resultados preocupantes: más del 90 % de los participantes afirmaron haber presenciado o sufrido algún tipo de abuso emocional o acoso mientras jugaban en línea. Además, los resultados muestran patrones preocupantes relacionados con el tipo de acoso más frecuente Tabla 2.1 y los videojuegos donde se experimenta con mayor intensidad este comportamiento Tabla 2.2.

Tipo de acoso	Porcentaje
Sobrenombres ofensivos	53 %
Racismo	44 %
Stalking	37 %
Discurso de odio	36 %
Insultos	35 %
Lenguaje explícito	34 %
Swatting	26 %
Flaming	26 %
Amenazas físicas	22 %
Doxxing	20 %

Cuadro 2.1: Tipos de acoso experimentados por jugadores en línea **Fuente:** [1]

Tipo de videojuego	Porcentaje
Shooters	52 %
Multiplayer Online Battle Arena (MOBA)	45 %
Estrategia en Tiempo Real	27 %
Juego de rol	23 %
Deportes	21 %

Cuadro 2.2: Tipo de videojuegos con los mayores abusos **Fuente:** [1]

2.2. Impacto del Lenguaje Ofensivo

El portal PantallasAmigas presenta un análisis sobre los efectos de los comentarios negativos en redes sociales y otros espacios digitales, basado en un estudio realizado por la Fundación MAPFRE y la Universidad de Deusto [4]. El estudio encuestó a 2520 personas españolas (49 % hombres y 51 % mujeres), con el objetivo de conocer las percepciones sobre el impacto emocional que tienen las críticas, los insultos y otros tipos de interacciones negativas en internet. Entre los hallazgos más relevantes, destaca que las personas reaccionan con más ansiedad, miedo, tristeza y problemas de sueño tras recibir un comentario negativo. Además, las mujeres son las más afectadas en este tipo de situaciones, ya que llegan a sufrir hasta más del doble de inseguridad que los hombres (22 % en mujeres y 8 % en hombres). Estas conclusiones se ilustran mediante cuadros estadísticos incluidos en el informe [5].

Figura 2.4: Uso de redes sociales según el sexo. Fuente: Adaptado de [4].

Figura 2.5: Temática de los comentarios negativos recibidos según el sexo. Fuente: Adaptado de [4].

Figura 2.6: Reacción emocional según el sexo. Fuente: Adaptado de [4].

2.3. Ejemplos de incidentes notorios con comentarios ofensivos

La Figura 2.7 presenta una serie de publicaciones auténticas recogidas de distintas redes sociales, que evidencian la continua presencia de lenguaje ofensivo en estas plataformas, a pesar de contar con mecanismos de moderación automatizada y humana.

Figura 2.7: Capturas de pantalla en redes sociales **[Elaboración Propia]**

Sin embargo, este problema no se limita únicamente a redes sociales. También se extiende a otros entornos digitales como los servicios de transmisión en vivo y los videojuegos en línea. En la Figu-

ra 2.8 se expone un caso registrado durante la emisión de una teleserie para todo público en la plataforma Kick, donde se visualizaron comentarios ofensivos en el chat en tiempo real. Por su parte, la Figura 2.9 muestra un ejemplo de contenido inapropiado identificado dentro del entorno competitivo del videojuego Valorant.

Figura 2.8: Ofensividad en Kick **[Elaboración Propia]**

Figura 2.9: Ofensividad en Valorant **[Elaboración Propia]**

Por otro lado, si bien persiste la circulación de mensajes ofensivos sin restricción, también se han documentado casos en los que los sistemas de moderación censuran erróneamente comentarios legítimos. En la plataforma TikTok, por ejemplo, se han reportado situaciones en las que publicaciones no ofensivas fueron retiradas o limitadas, como se detalla al final de esta sección.

Figura 2.10: Ejemplos de comentarios censurados injustamente en la plataforma TikTok **[Elaboración Propia]**

2.4. Mercado Global

2.4.1. Mercado Mundial de Moderación de Contenido Automatizado

El mercado mundial de moderación de contenido automatizado ha experimentado un crecimiento significativo en los últimos años, impulsado por el aumento del contenido generado por usuarios en plataformas digitales como redes sociales, foros en línea y servicios de streaming [6]. El mercado se basa en tecnologías de Inteligencia Artificial (IA) y Machine Learning (ML) para identificar y eliminar contenido perjudicial de manera eficiente, incluso sin necesidad de moderadores humanos. El tamaño del mercado mundial de moderación de contenido automatizado se valoró aproximadamente en 0,83 billones de dólares en 2023 y se pronostica 3,4 en 2032, esto con una Tasa de Crecimiento Anual Compuesta (CAGR) de 18,5 % de 2023 a 2032.

Figura 2.11: Tamaño estimado del mercado global de moderación de contenido automatizado. Adaptado y traducido de [6].

2.4.2. Mercado de Soluciones de Moderación de Contenido

Según el mercado de soluciones de moderación de contenido, el mercado se divide en soluciones locales y basadas en la nube, donde las grandes empresas dominan el mercado debido a sus requisitos generalizados de control de contenido, pero las Pequeña y Mediana Empresa (PYME) están aumentando inesperadamente gracias a las ofertas de moderación [7].

El mercado de soluciones cuenta con una CAGR de aproximadamente 13,4 % de 2024 a 2032, este mercado se puede segmentar por aplicación o por tipo:

El mercado de soluciones por aplicación se puede clasificar en las redes sociales, el minorista de comercio electrónico y otros. Mientras que según el tipo, el mercado global se puede clasificar en servicios, software y plataforma, donde se pronostica una mayoría de servicios para el 2032, según la Figura 2.12.

Figura 2.12: Mercado Global de soluciones de moderación de contenido pronosticado al año 2032. Adaptado y traducido de [7].

2.4.3. Mercado Global de Servicios de Moderación de Contenido

Según datos recientes de SNS Insider (2024), el mercado global de servicios de moderación de contenido fue valorado en USD 10.01 mil millones en 2023 y se proyecta que alcanzará los USD 30.75 mil millones para 2032, registrando una CAGR del 13.33 % en el período 2024–2032 [8]. Este crecimiento refleja la creciente necesidad de herramientas de moderación automatizada, impulsada por el aumento del contenido generado por usuarios en plataformas digitales.

Se resume parte del informe en la Tabla 2.3 y la Tabla 2.4.

Segmento	Participación
Grandes Empresas	66 %
Medios y Entretenimiento	28 %
Imágenes	47 %
América del Norte	40 %

Cuadro 2.3: Participación en ingresos del mercado de servicios de moderación de contenido (2023) [Elaboración Propia]

Segmento	CAGR Estimado
PYME	15,14 %
Retail y Comercio Electrónico	15,39 %
Video	16,18 %
Asia-Pacífico	15,04 %

Cuadro 2.4: CAGR estimado en servicios de moderación de contenido (2024–2032) [Elaboración Propia]

Finalmente, se extrae una comparativa de las predicciones por los estudios de mercado.

Figura 2.13: Proyección de los mercados globales al año 2032 [Elaboración Propia]

Capítulo 3

Mercado Objetivo

3.1. Identificación del Mercado Objetivo

3.2. Identificación del Mercado Objetivo

El crecimiento acelerado de las redes sociales y plataformas digitales ha generado una necesidad cada vez mayor de herramientas que fomenten entornos de interacción seguros y respetuosos. Si bien las grandes plataformas sociales ya cuentan con infraestructuras avanzadas de moderación, tanto automatizada como humana, esto no significa que el problema del lenguaje ofensivo esté resuelto. Sin embargo, la adopción de nuevas soluciones en estos entornos puede resultar limitada por las altas barreras tecnológicas y políticas.

Por ello, resulta más estratégico enfocar los esfuerzos iniciales en sectores donde la problemática persiste y las soluciones actuales son aún incipientes o poco accesibles. A continuación, se describen los mercados en los que la propuesta tecnológica tendría mayor impacto y viabilidad de implementación:

1. **Plataformas de streaming en vivo:** Espacios como Kick o Twitch presentan una alta velocidad de interacción, con miles de mensajes por minuto durante transmisiones en directo. La moderación manual resulta insuficiente, por lo que un sistema automatizado puede actuar como apoyo eficaz, especialmente en contenidos dirigidos a públicos jóvenes o menores de edad.
2. **Comunidades en línea:** Entornos con alta participación textual y fuerte presencia de usuarios hispanohablantes, donde la moderación suele depender únicamente de configuraciones básicas o listas de palabras prohibidas. Este grupo incluye servidores de Discord, grupos de Telegram y foros como Reddit. Cabe destacar que Reddit ha incorporado moderación automatizada mediante Perspective API, desarrollada por Google [9].
3. **Medios de comunicación digital:** Portales de noticias y sitios informativos que permiten la participación del público a través de comentarios. Estos espacios requieren mantener una conversación pública constructiva sin comprometer su reputación institucional. Medios como *The New York Times* y *El País* ya han incorporado tecnologías como Perspective API para gestionar este desafío [9].
4. **Plataformas educativas virtuales:** Aunque menos explotado, el sector educativo presenta un alto potencial, en especial en entornos con participación estudiantil

activa. Como ejemplo destacado, el Departamento de Educación de Australia Meridional, en colaboración con Microsoft, ha

implementado la herramienta “EdChat”, apoyada por el servicio Azure AI Content Safety, con el objetivo de crear espacios digitales seguros para el aprendizaje.

3.3. Elección del Mercado Objetivo

Los medios digitales que permiten comentarios abiertos al público enfrentan un desafío constante en la gestión de expresiones ofensivas, discursos de odio y comportamientos disruptivos. Este tipo de contenido no solo perjudica la experiencia del lector, sino que también compromete la imagen institucional del medio y su capacidad para ofrecer espacios de diálogo respetuoso.

La elección de este sector responde a múltiples factores. En primer lugar, existe una necesidad evidente y persistente de soluciones eficientes, ya que muchas plataformas aún dependen de procesos manuales o herramientas básicas para moderar los comentarios. En segundo lugar, el volumen diario de interacciones es considerable, dificultando la revisión exhaustiva sin el apoyo de sistemas automatizados. Finalmente, el lenguaje ofensivo puede deteriorar gravemente la percepción pública del medio, afectando su credibilidad, su relación con los usuarios y su sostenibilidad a largo plazo.

La adopción exitosa de tecnologías como Perspective API evidencia esta demanda. De acuerdo con datos de Jigsaw (subsidiaria de Google), esta API procesa más de 500 millones de solicitudes diarias, y ha sido integrada en medios internacionales como *The New York Times*, *El País* y Cofina. Estos casos muestran cómo una herramienta de moderación automatizada puede reducir significativamente los niveles de toxicidad, mejorar la eficiencia del proceso editorial y ampliar la participación del público, al aumentar el número de artículos abiertos a comentarios y reducir la carga de la moderación humana [10].

3.4. Panorama Nacional en Medios Digitales

En el contexto nacional, numerosos medios digitales han optado por restringir o suprimir los espacios públicos de comentarios en sus sitios web. Esta decisión suele estar motivada por la complejidad que implica la moderación efectiva de contenidos ofensivos, inapropiados o potencialmente dañinos. La ausencia de herramientas automatizadas adaptadas al idioma español acentúa esta dificultad, lo que lleva a muchas redacciones a limitar la interacción directa con su audiencia como medida preventiva.

Una situación comparable se presenta en programas de televisión que incluyen la participación del público en tiempo real, como transmisiones en vivo o formatos interactivos. En estos entornos, los mensajes enviados deben pasar por filtros previos a su difusión, con el objetivo de evitar expresiones discriminatorias, agresivas o inadecuadas para una audiencia general.

Capítulo 4

Oferta Tecnológica Mundial

4.1. Tecnologías Utilizadas en la Detección de Lenguaje Ofensivo

En respuesta al aumento de contenido ofensivo y discursos de odio en entornos digitales, diversas empresas tecnológicas han implementado soluciones propias de moderación, basadas principalmente en inteligencia artificial. Algunas de estas tecnologías se mantienen de uso interno, mientras que otras se ofrecen como servicios comerciales para su integración en plataformas de terceros. A continuación, se presentan las principales compañías y sus respectivas soluciones.

4.1.1. Google

Jigsaw, una incubadora tecnológica de Google, desarrolló en 2017 Perspective API. La creación de esta herramienta respondió a la creciente preocupación por los comentarios abusivos y el discurso de odio en línea, especialmente en secciones de comentarios de medios digitales y redes sociales [9].

La herramienta utiliza técnicas avanzadas de PLN y aprendizaje profundo (deep learning), basadas principalmente en modelos de redes neuronales profundas, principalmente basado en modelo de tipo transformer. Si bien se diseñó inicialmente para el idioma inglés, ha tenido implementaciones experimentales en otros idiomas.

Perspective es de disponibilidad pública y gratuita mediante Application Programming Interface (API). Utilizada por medios como The New York Times y Wikipedia.

4.1.2. Meta

Meta (anteriormente Facebook Inc.) ha invertido durante más de una década en el desarrollo de tecnologías propias para combatir el lenguaje ofensivo, el discurso de odio y el acoso en sus plataformas. La compañía ha consolidado un enfoque mixto, combinando algoritmos de IA con equipos de moderadores humanos distribuidos globalmente [11].

Meta emplea modelos avanzados de deep learning y PLN. A continuación, se detallan inversiones realizadas en tecnología por parte de Meta:

- Linformer: Analiza contenido en Facebook e Instagram en diversas regiones de todo el mundo.

- Reinforced Integrity Optimizer: Aprende de las señales online para mejorar su capacidad de detectar el lenguaje que incita al odio.
- XLM y XLM-R: Herramientas de idiomas con las que se crean clasificadores que entienden el mismo concepto en varios idiomas. Se incorpora el modelo transformer Roberta.

Estas tecnologías se aplican directamente en las plataformas de Meta para filtrar, ocultar o eliminar contenido ofensivo antes de que sea ampliamente distribuido.

4.1.3. Microsoft

Microsoft ha desarrollado diversas soluciones enfocadas en la moderación de contenido, integradas en su ecosistema de servicios en la nube Azure. Inicialmente, esta necesidad fue cubierta por *Azure Content Moderator*, una herramienta diseñada para identificar automáticamente contenido ofensivo o inapropiado en texto, imágenes y videos, con aplicaciones en foros, redes sociales, chats en línea y otras plataformas de interacción digital.

No obstante, esta solución fue declarada obsoleta en febrero de 2024 y será retirada por completo en 2027 [12]. En su reemplazo, Microsoft presentó **Azure AI Content Safety**, una alternativa más moderna y robusta, orientada tanto a contenido generado por usuarios como por modelos de inteligencia artificial generativa.

Azure AI Content Safety emplea técnicas avanzadas de aprendizaje automático y procesamiento de lenguaje natural para analizar contenido textual e imágenes, categorizándolos según su nivel de riesgo en las siguientes áreas:

- **Odio:** discursos discriminatorios o incitaciones a la violencia.
- **Sexual:** material explícito o sugestivo.
- **Violencia:** representaciones gráficas o amenazas explícitas.
- **Autolesiones:** contenido relacionado con suicidio o daño autoinfligido.

Esta herramienta está disponible como API REST dentro del entorno Azure, con un esquema comercial de pago por uso. Su flexibilidad permite su integración en aplicaciones web, servicios de atención al cliente, plataformas educativas, entre otros.

4.1.4. Twitch

Twitch, la reconocida plataforma de streaming en vivo propiedad de Amazon, ha implementado un sistema mixto de moderación que combina inteligencia artificial, parámetros configurables y participación activa de moderadores humanos. Uno de sus desarrollos más relevantes es **AutoMod**, una herramienta integrada que analiza en tiempo real los mensajes del chat durante las transmisiones en vivo [13].

AutoMod está basado en modelos de lenguaje que han sido entrenados para identificar expresiones ofensivas, discriminatorias o inapropiadas. Entre los principales tipos de contenido que detecta se encuentran:

- Insultos, lenguaje sexual o vulgaridades.
- Discursos de odio o incitación a la violencia.
- Comentarios contextualmente dañinos según la comunidad.

A diferencia de sistemas que eliminan contenido automáticamente, AutoMod actúa como un filtro intermedio: retiene los mensajes sospechosos y permite a los moderadores humanos decidir si deben ser publicados o descartados. Esta funcionalidad está integrada en la plataforma y disponible para todos los canales de Twitch, aunque no se encuentra habilitada como producto independiente para otras plataformas.

4.1.5. Otras Plataformas

Plataformas como Discord y Telegram han consolidado su papel como espacios de interacción comunitaria, permitiendo la formación de grupos temáticos con altos niveles de autonomía. Esta arquitectura descentralizada, donde cada servidor o canal establece sus propias reglas de convivencia, ha impulsado la necesidad de herramientas flexibles para la moderación automatizada.

Discord, por ejemplo, incorporó en 2022 una funcionalidad nativa denominada **AutoMod**, orientada a prevenir la publicación de mensajes con lenguaje ofensivo, contenido sensible o comportamientos considerados spam, antes de que sean visibles públicamente [14]. A ello se suma la posibilidad de integrar bots externos como Dyno, MEE6 o Carl-bot, algunos de los cuales emplean técnicas de inteligencia artificial o se vinculan con servicios externos como Perspective API para mejorar la calidad de la moderación.

En el caso de Telegram, la plataforma destaca por ofrecer una API altamente personalizable, lo que ha favorecido el desarrollo de bots de moderación por parte de su comunidad. Aunque no cuenta con un sistema nativo de moderación automática comparable al de Discord, su flexibilidad ha permitido implementar soluciones que abordan tareas como el control de spam, la detección de palabras sensibles o la gestión dinámica de participantes en canales y grupos [15].

4.2. Precio del Mercado

Los servicios actuales cuentan con una disponibilidad variada y tienen los siguientes precios mostrados en la Tabla 4.1.

Plataformas como Telegram y Discord admiten y contienen numerosos bots creados por la comunidad y terceros que cuentan con sus propios planes de pago, los cuales ofrecen servicios adicionales diseñados para automatizar tareas, fomentar la participación, moderar de manera superficial mediante filtros de palabras, integrarse con servicios externos (Youtube, Twitch, etc). Sin embargo, la mayoría de estos bots no emplean tecnologías avanzadas para la moderación de contenido, y muchos no están preparados para manejar el idioma español de manera eficiente, esto es debido a que están enfocados en la gestión de comunidades y moderación basada en listas de palabras.

Plataforma	Servicio	Categoría	Precio
Google	Perspective API	API Pública	Gratuita, 1 consulta por segundo
ZPK System	ZPK Moderator	API Pública	\$ 1.1 / 1000 requests (<500 caracteres)
Azure	Azure AI Content Safety	API Pública	\$ 0,38 / 1.000 requests (1000 caracteres)
Komprehend.io	Abusive Content Classifier API	API Privada	Bajo contacto con proveedor
Hive AI	Hive Moderation	API Privada	\$0.50 / 1000 requests
Microsoft	Community Sift	Servicio de Moderación	Depende de Contrato
Shaip	Moderación de Contenido	Servicio de Moderación	Depende de Contrato
Gearinc	Moderación de Contenido	Servicio de Moderación	Depende de Contrato
Twitch	Automod	Nativo en Twitch	Gratuito
Discord	Automod	Nativo en Discord	Gratuito
Discord	Dyno	Nativo en Discord	Plan Estándar 4.99 \$/mes
Telegram	Combot	Nativo en Telegram	Gratuito

Cuadro 4.1: Servicios de moderación de contenido disponibles en distintas plataformas (elaboración propia a partir de información pública de los sitios oficiales) **[Elaboración Propia]**

4.3. Limitaciones de la Oferta Actual

Pese a los avances tecnológicos, las soluciones actuales para la moderación automática de contenido presentan diversas limitaciones que restringen su efectividad en contextos hispanohablantes:

- **Idioma y regionalismos:** la mayoría de los sistemas están entrenados para inglés y no logran buenos resultados con expresiones ofensivas en español, sobre todo en países latinoamericanos.
- **Accesibilidad:** muchas herramientas de moderación no son abiertas o requieren acuerdos comerciales complejos para acceder a APIs completas.
- **Enfoque generalista:** los modelos actuales suelen enfocarse en términos ofensivos genéricos, sin comprender contexto, ironía, o nuevas formas de lenguaje dañino.

Capítulo 5

Flujo de Ingresos Proyectados

Para ingresar al mercado, una estrategia razonable sería ofrecer el servicio a un precio competitivo dentro de los rangos más accesibles actualmente disponibles. De acuerdo con la Tabla 4.1, se ha decidido establecer un costo de \$0.36 por cada 1000 mensajes procesados.

Actualmente, entre los clientes públicos de este tipo de servicios se encuentran plataformas de medios digitales como *El País* y *The New York Times*, las cuales pueden generar diariamente en promedio alrededor de 200 contenidos periodísticos, acompañados de más de 400 comentarios por publicación.

Para efectos del presente análisis, se considerará un escenario hipotético en el cual las plataformas de medios digitales nacionales recibirán un volumen equivalente al que muestra la plataforma *The New York Times* (tener en cuenta que la plataforma internacional recibe más mensajes de los que se ha mencionado, solo que estos no son publicados porque ya fueron moderados). Además se considera un crecimiento proyectado según la CAGR del 13,4 %, compatible con el mercado de soluciones de moderación. Estos valores se muestran en la Tabla 5.1.

Parámetro	Valor
Precio por 1.000 mensajes	\$0.36 USD
Mensajes procesados diarios	80.000 mensajes
Ingresos diarios	28.8 USD
Ingresos mensuales	864 USD
Mensajes procesados anuales	29,200,000 mensajes
Tasa de crecimiento anual (CAGR)	13.4 %

Cuadro 5.1: Estimaciones por Servicio **[Elaboración Propia]**

Bajo estas consideraciones, la Tabla 5.2 y la Figura 5.1 presentan la proyección de ingresos anuales por cliente para el periodo 2026–2031. Se parte del supuesto de que el precio del servicio permanece constante en \$0.36 USD por cada 1,000 mensajes procesados, y que el crecimiento anual en el uso del servicio por parte de un cliente sigue una CAGR del 13.4 %, coherente con el crecimiento estimado del mercado global de soluciones de moderación de contenido.

Figura 5.1: Flujo de Ingresos para un cliente **[Elaboración Propia]**

Año	Miles de mensajes aprox.	Ingresos
2026	29,200	\$10,512.00
2027	33,113	\$11,920.61
2028	37,550	\$13,517.97
2029	42,582	\$15,329.38
2030	48,288	\$17,383.51
2031	54,758	\$19,712.90

Cuadro 5.2: Proyección de ingresos para un cliente **[Elaboración Propia]**

Bajo este escenario, se proyecta que un cliente que inicialmente procesa 29,200 millones de mensajes en 2026 aumentará progresivamente su volumen de uso, alcanzando aproximadamente 54.76 millones de mensajes en 2031. Como consecuencia, el ingreso anual generado por dicho cliente pasaría de \$10,512 USD en 2026 a \$19,712 USD en 2031.

Esta proyección refleja un crecimiento sostenido en el uso del servicio, lo cual podría derivarse del aumento en la actividad digital de los clientes, una mayor necesidad de moderación automatizada, o la consolidación del servicio como parte integral de sus operaciones.

En la Figura 5.2 se asume que el número de clientes también aumenta y además, el volumen de mensajes procesados por cada cliente aumenta anualmente siguiendo la CAGR del 13.4 %, alineada con el crecimiento estimado del mercado de soluciones de moderación de contenido.

Figura 5.2: Flujo de Ingresos Totales **[Elaboración Propia]**

Este enfoque refleja una evolución más realista del negocio en una etapa de expansión:

- Por un lado, el número de clientes crece conforme más empresas adoptan servicios automatizados de moderación de lenguaje.
- Por otro lado, cada cliente tiende a procesar un volumen cada vez mayor de mensajes, a medida que integran más áreas de su plataforma o crecen en usuarios.

Capítulo 6

OffendES y su aplicación en el proyecto

El corpus OffendES representa un aporte fundamental para la comunidad hispana de PLN, esto es debido a que la mayoría de los recursos disponibles para entrenar y evaluar estos sistemas han sido desarrollados para el idioma inglés, lo que limita significativamente la investigación y el desarrollo de soluciones adaptadas a contextos hispanohablantes.

OffendES, se trata de un conjunto de datos en español diseñado específicamente para la detección de lenguaje ofensivo, compuesto por comentarios recolectados de diferentes redes sociales y anotados manualmente.

6.1. Características del corpus OffendES

6.1.1. Fuentes de datos y recolección

El proceso de recolección de datos se llevó a cabo entre febrero y marzo de 2020, tomando como referencia tres plataformas ampliamente utilizadas por usuarios jóvenes (entre 18 y 24 años): Twitter, Instagram y YouTube. Estas redes sociales fueron seleccionadas por su alto nivel de interacción y su relevancia en el ecosistema digital.

Se eligieron 12 personalidades influyentes del entorno español, seis hombres y seis mujeres, que se caracterizan por su alta exposición mediática y participación en controversias en línea. Para cada uno de ellos, se extrajeron los comentarios correspondientes a sus últimas 50 publicaciones. En el caso de Twitter y YouTube, la recopilación se realizó mediante APIs oficiales; para Instagram, se utilizaron técnicas de web scraping, estableciendo un máximo de 2,000 respuestas por publicación.

Como resultado, se recolectaron un total de 283,622 comentarios, de los cuales 23,788 incluían términos con potencial ofensivo, identificados a partir de lexicones previamente definidos. Posteriormente, se conformó un conjunto final de 60,000 comentarios (23,788 ofensivos y 36,212 no ofensivos), aplicando criterios de diversidad léxica para evitar redundancias y asegurar representatividad.

6.1.2. Esquema de anotación

La anotación del corpus fue realizada mediante la plataforma de *crowdsourcing* Amazon Mechanical Turk (MTurk), empleando únicamente trabajadores ubicados en España para asegurar la comprensión contextual del lenguaje.

Se utilizó un esquema de cinco etiquetas diferenciadas, con el objetivo de capturar

distintos matices del lenguaje ofensivo:

- **OFP** (Ofensivo hacia una persona): Comentarios que agreden directamente a un individuo.
- **OFG** (Ofensivo hacia un grupo): Comentarios dirigidos contra colectivos específicos, como género, etnia, orientación sexual o ideología.
- **OFO** (Ofensivo hacia otras entidades): Comentarios que atacan instituciones, marcas, eventos u organizaciones.
- **NOE** (No ofensivo con lenguaje vulgar): Uso de lenguaje soez sin intención de ofender.
- **NO** (No ofensivo): Comentarios neutros o sin lenguaje perjudicial.

El corpus se organizó en dos subconjuntos según la cantidad de anotadores por comentario:

- **3-Ann**: Conjunto de 44,951 comentarios, cada uno anotado por tres personas.
- **10-Ann**: Conjunto de 14,989 comentarios, cada uno evaluado por diez anotadores, lo que permite generar vectores de confianza para tareas avanzadas como clasificación multietiqueta.

Los atributos presentes en el corpus son los siguientes:

- **comment_id**: Identificador único de cada comentario. **media**: Plataforma de origen del comentario (Instagram, Twitter o YouTube).
- **influencer**: Nombre del influencer asociado a la publicación.
- **influencer_gender**: Género del influencer (man o woman). **comment**: Texto completo del comentario.
- **ann1** – **ann10**: Etiquetas asignadas por cada anotador individual. Los valores posibles son: OFP, OFG, OFO, NOE, NO y None.
- **label**: Etiqueta final asignada a cada comentario, resultante de un proceso de consenso entre los anotadores.

6.1.3. Distribución y diversidad

Una característica notable del corpus es su desbalance natural: tanto las etiquetas como las plataformas e influencers no están distribuidos uniformemente. La mayoría de los comentarios provienen de YouTube (alrededor del 75 %), seguido de Instagram (18 %) y Twitter (6 %). Del mismo modo, ciertos influencers como Dalas concentran más del 25 % de los comentarios.

En cuanto a la longitud y variedad del lenguaje, los comentarios muestran diferencias significativas según la plataforma. Por ejemplo, los comentarios de YouTube tienden a ser más extensos (promediando 189 caracteres) y diversos en vocabulario, mientras que los de Instagram son más breves (114 caracteres en promedio) y lexicalmente más pobres. La medida de diversidad léxica también reveló que los comentarios ofensivos (especialmente OFP y NOE) tienden a tener una menor riqueza léxica que los no ofensivos.

Capítulo 7

Modelos Transformers y su aplicación en el proyecto

Los modelos transformers son un tipo de modelo de Deep Learning, que evolucionaron significativamente el campo del PLN, los cuales han demostrado un rendimiento sobresaliente en tareas como clasificación de texto, análisis de sentimientos y detección de lenguaje ofensivo [16].

Introducidos por Vaswani et al. (2017) en el artículo *Attention Is All You Need*, los transformers reemplazan las estructuras secuenciales tradicionales como las Redes Neuronales Recurrentes (RNN) o la Memoria a Corto Plazo (LSTM) por mecanismos de atención, permitiendo que el modelo evalúe de forma paralela todas las palabras de un texto y determine las relaciones contextuales entre ellas. Esto ha resultado en modelos más precisos y rápidos para tareas de lenguaje natural [17].

7.1. Ventajas del Modelo

Los modelos basados en la arquitectura Transformer destacan por emplear un mecanismo denominado self-attention, que les permite analizar la relevancia de cada palabra dentro de un texto en relación con todas las demás, sin importar su posición. Esto representa una ventaja frente a modelos secuenciales, que tienden a perder contexto cuando las dependencias entre palabras son muy largas.

Gracias a esta capacidad, los Transformers son especialmente eficaces para capturar relaciones complejas y de largo alcance dentro del lenguaje natural. Además, su arquitectura completamente paralelizable posibilita una aceleración significativa en los tiempos de entrenamiento, superando en eficiencia a modelos tradicionales.

La estructura de un Transformer está compuesta por codificadores (encoders) y decodificadores (decoders). Para tareas de clasificación de texto, como la detección de lenguaje ofensivo, se hace uso únicamente de los encoders. Un ejemplo representativo de este enfoque es el modelo Bidirectional Encoder Representations from Transformers (BERT), que ha demostrado un desempeño sobresaliente en múltiples tareas de comprensión del lenguaje.

El uso de Transformers ha marcado un antes y un después en el procesamiento de lenguaje natural, mejorando significativamente tareas como análisis de sentimientos, clasificación textual, traducción automática y respuesta a preguntas. En este proyecto, se aprovechan sus capacidades contextuales avanzadas para identificar lenguaje ofensivo en español con mayor precisión.

7.2. Proceso en el Proyecto

A continuación, se describe el funcionamiento interno que cumple el modelo Transformer:

1. **Tokenización y Embedding:** El texto de entrada se segmenta en subpalabras o tokens mediante un tokenizador especializado. Posteriormente, cada token es convertido en un vector numérico, conocido como embedding, que contiene información semántica aprendida durante el preentrenamiento del modelo.
2. **Codificación con Capas de Atención:** Estos vectores se procesan a través de varias capas de atención. En cada una, el modelo calcula la relación entre palabras mediante pesos de atención, permitiéndole interpretar el texto de forma contextual. Este mecanismo es clave para comprender el significado global, incluso en frases complejas o ambiguas.
3. **Normalización y Proyección:** Tras cada capa de atención, se aplican técnicas de normalización y conexiones residuales que estabilizan el aprendizaje y ayudan a conservar información significativa durante el flujo de datos por el modelo.
4. **Capa de Clasificación:** Finalmente, el vector resultante es procesado por una capa final de clasificación, que produce una salida binaria (ofensivo o no ofensivo) en función de la probabilidad asignada a cada clase.

Capítulo 8

Diseño de los datos de entrada

Para la preparación de los datos de entrada en el Producto Mínimo Viable (MVP), se decidió reestructurar el esquema de etiquetado original —que contemplaba cuatro categorías— hacia una clasificación binaria: ofensivo y no ofensivo. Esta simplificación permite evaluar el desempeño del modelo en un escenario generalizado de detección de lenguaje ofensivo.

Adicionalmente, se realizó una limpieza de los metadatos presentes en el corpus, conservando únicamente los campos relevantes: comment y label. El conjunto de datos fue obtenido desde un repositorio público en GitHub [18].

Inicialmente, se parte de un total de 30.416 comentarios, cuya distribución por categorías se presenta en la Figura 8.1.

Figura 8.1: Distribución general de etiquetado **[Elaboración Propia]**

A continuación, se muestran ejemplos de comentarios etiquetados, seleccionados aleatoriamente:

- **NO:** Yo ya quiero verloooo! Sois increíbles, a veces es tan complicado trabajar con otra personas, por la diferencia de ideas ect y ustedes os competreéis muy bien!!!
- **OFP:** MAS TONTA QUE UN ZAPATO.
- **NOE:** Estoy es pura mierda

- **OFG:** Bueno donde estan esas feministas que se ponen la medallita de buena persona diciendo "la víctima nunca es culpable"por en este caso tu hermana es la víctima de estas personas asquerosas, acosadores de mierda.

Posteriormente, el conjunto de datos se dividió en tres subconjuntos para el desarrollo del modelo:

- **Entrenamiento (train):** Utilizado para ajustar los parámetros del modelo.
- **Validación (dev):** Sirve para ajustar los hiperparámetros y evaluar el desempeño durante el entrenamiento.

Figura 8.2: Distribución de etiquetado por conjunto [Elaboración Propia]

- **Prueba (test):** Permite medir el rendimiento final del modelo sobre datos no vistos previamente.

Posteriormente, se redujo la cantidad de datos para disminuir la carga computacional a la hora de entrenar el modelo y se llevó a cabo la recategorización del etiquetado original hacia la clasificación binaria mencionada previamente. La distribución resultante se muestra en la Figura 8.3.

Figura 8.3: Distribución actualizada del etiquetado binario **[Elaboración Propia]**

Los gráficos presentados en este capítulo fueron generados mediante las bibliotecas *pandas* y *matplotlib* de Python, ampliamente utilizadas para el análisis y visualización de datos. Además, estos datasets modificados se guardan a partir de la función *load_processed_offenders* en Listado 8.1.

Listing 8.1. Función load_processed_offendes

```
def load_processed_offendes():  
    """Carga los archivos TSV procesados."""  
    return {  
        "train": pd.read_csv(os.environ.get("OF_PROCESSED_PATH")+  
            "train_processed.csv").copy(),  
        "dev": pd.read_csv(os.environ.get("OF_PROCESSED_PATH")+  
            "dev_processed.csv").copy(),  
        "test": pd.read_csv(os.environ.get("OF_PROCESSED_PATH")+  
            "test_processed.csv").copy()  
    }
```

Capítulo 9

Diseño y Despliegue del modelo de clasificación

9.1. Diseño del Modelo

9.1.1. Tokenización

Luego de ajustar los datos de entrada, el siguiente paso es el de la tokenización que consiste en dividir un texto en unidades más pequeñas (tokens), que pueden ser palabras, subpalabras o caracteres. Para modelos como BETO (basado en BERT), se usan subpalabras para manejar vocabulario limitado y palabras desconocidas.

Cargaremos el tokenizador oficial de BETO, que ya conoce las reglas del español y su vocabulario preentrenado, en Listado 9.1.

Listing 9.1. Función `load_tokenizer`

```
1 def load_tokenizer():
2     """
3     Carga el tokenizador desde el modelo preentrenado.
4     """
5
6     # Cargar el tokenizador
7     tokenizer = AutoTokenizer.from_pretrained("dccuchile/bert-base-spanish-wwm
8         -cased")
9
10    return tokenizer
```

A continuación, tras realizar la limpieza de los datos (ver Listado 8.1) y cargar el tokenizador correspondiente (ver Listado 9.1), se procede a aplicar la tokenización sobre los comentarios del conjunto de datos. Para ilustrar este proceso, se implementó una función que permite seleccionar un comentario aleatorio y mostrar los resultados de su tokenización. A continuación, se muestra la salida de dicha función:

```
1 "mensaje": "Ejemplo de dato tokenizado",
2 "indice": 12614,
3 "texto decodificado": "Aclaro : el es un trastorno psiquiátrico que consiste
4     en que la
5     persona que lo
```



```
1 padece se autolesiona o pone en riesgo su salud para enfermar o resultar
  herido con el afán
2 de conseguir
3 atención médica. No es como un hipocondríaco que piensa que está enfermo y
  exige pruebas
4 médicas. El falsea
5 pruebas o se daña a sí mismo a sabiendas que no está enfermo, sino sólo para
  recibir atención
6 y cuidados de su
7 entorno. El por poderes es lo mismo, sólo que el paciente que lo padece en vez
  de
8 autolesionarse, lesiona a
9 otra persona / falsea pruebas para recibir indirectamente esa atención médica
  que se le
10 presta al otro. Lo
11 típico es madres - hijos, cuidadores - ancianos, etc.",
12 "tokens": [
13     "[CLS] ",
14     "Ac",
15     "##laro",
16     ":",
17     "el",
18     "[UNK] ",
19     "es",
20     "un",
21     "trastorno",
22     "psiquiá"
23 ],
24 "input_ids": [
25     4,
26     2810,
27     2316,
28     1181,
29     1040
30 ],
31 "attention_mask": [
32     1,
33     1,
34     1,
35     1,
36     1
37 ],
38 "etiqueta": 0
39 }
```

A modo ilustrativo, se presenta un ejemplo de los resultados obtenidos tras aplicar la tokenización a uno de los comentarios del dataset:

- **índice:** Indica el índice o la posición del comentario en el dataset.

- **texto_decodificado:** Reconstrucción del texto original a partir de los IDs de los tokens *input_ids*.
- **tokens:** Lista de subpalabras/palabras generadas por el tokenizador. Incluye:
 - **[CLS]:** Token especial para clasificación (usado en modelos como BERT).
 - **[UNK]:** Token desconocido (indica que una palabra no está en el vocabulario del tokenizador).
 - **##:** Prefijo que indica que se trata de una continuación del token anterior.
- **input_ids:** Representan los identificadores numéricos asignados a cada token. Esta secuencia es la que efectivamente se proporciona como entrada al modelo Transformer.
- **attention_mask:** Una secuencia binaria que indica qué posiciones deben ser consideradas (valor 1) y cuáles ignoradas (valor 0), generalmente usada para distinguir entre contenido real y padding.
- **etiqueta:** corresponde a la clase a la que pertenece según la tarea de, en este caso 0 indica no ofensivo; mientras que 1, ofensivo.

9.1.2. Entrenamiento del Modelo

Tras la tokenización de los datos, el siguiente paso es la carga del modelo BETO definido en el Listado 9.2 y los datasets tokenizados previamente.

Listing 9.2. Función `load_model`

```
1 def load_model():
2     """
3     Carga el modelo desde el modelo preentrenado.
4     """
5
6     # Cargar el modelo
7     model = AutoModelForSequenceClassification.from_pretrained(os.environ.get(
8         "TRANSFORMER_MODEL"),
9         num_labels=2,
10        id2label={0: "no_ofensivo", 1: "ofensivo"},
11        label2id={"no_ofensivo": 0, "ofensivo": 1}
12    )
13
14    return model
```

Luego, se especifican parámetros clave para el entrenamiento, como el tamaño del batch o número de épocas y también se evalúa el desempeño del modelo en cada época usando la métrica F1.

9.1.3. Validación del Modelo

Tras ejecutar el proceso de entrenamiento del modelo, se procede a evaluar el modelo con el subconjunto de datos ‘test’ y se obtienen métricas fundamentales como el f1-score, la precisión y el recall, que permiten analizar el rendimiento del modelo en el conjunto de prueba.

A continuación se presentan las métricas obtenidas durante la evaluación del modelo binario. Estas permiten analizar su comportamiento en términos de precisión, cobertura y confiabilidad.

```
1 "message": "Métricas cargadas desde test.",
2   "métricas": {
3     "eval_loss": 0.7105175256729126,
4     "eval_model_preparation_time": 0.001,
5     "eval_precision": 0.32032322000304925,
6     "eval_recall": 0.8235985887887103,
7     "eval_f1": 0.46125137211855105,
8   }
9 }
```

Métrica	Valor	Interpretación
eval_precision	0.32 (32 %)	Alta tasa de falsos positivos: clasifica como ofensivos textos que no lo son.
eval_recall	0.82 (82 %)	Detecta correctamente los ofensivos.
eval_f1	0.46 (46 %)	Balance entre precisión y recall (idealmente >0.7).
eval_loss	0.71	Pérdida elevada: el modelo tiene poca confianza en sus predicciones.

Cuadro 9.1: Análisis de métricas del modelo [Elaboración Propia]

9.2. Despliegue del Modelo

Finalizada la etapa de entrenamiento y evaluación, el siguiente paso consiste en preparar el modelo para su integración en entornos reales. Esto implica generar una versión optimizada para producción, que pueda ser utilizada directamente para la clasificación de nuevos textos sin requerir intervención manual en el procesamiento.

Para lograrlo, se construye un pipeline de inferencia que agrupa tanto el modelo entrenado como el tokenizador correspondiente. Este pipeline permite automatizar y simplificar el proceso de predicción, facilitando su integración en servicios web, aplicaciones o interfaces programáticas.

La herramienta utilizada para este fin es la función pipeline del módulo **transformers** de Hugging Face, la cual proporciona una interfaz estándar para aplicar modelos de procesamiento de lenguaje

natural ya entrenados. Su principal ventaja radica en la capacidad de encapsular todos los componentes necesarios —modelo, tokenizador y configuración— en un objeto reutilizable y listo para producción.

Una vez almacenado el pipeline, es posible invocarlo de forma directa para realizar inferencias sobre nuevos textos. En este contexto, se implementa la función `classifier` (ver Listado 9.3), encargada de cargar el pipeline desde disco y aplicarlo a una entrada textual provista por el usuario. Como resultado, se obtiene la etiqueta asignada por el modelo y el nivel de confianza asociado a dicha predicción.

Listing 9.3. Función `classifier`

```

1 def classifier(event):
2     #Cargar el pipeline guardado
3     classifier = pipeline(
4         "text-classification",
5         model=Path(os.environ.get("TRANSFORMER_PATH")) / "pipeline",
6         tokenizer = tok.load_tokenizer()
7     )
8
9     #Clasificar un texto nuevo
10    resultado = classifier(event['texto'])
11
12    return {
13        "mensaje": "Clasificación completada.",
14        "resultado": {
15            "texto": event['texto'],
16            "etiqueta": resultado[0]['label'],
17            "confianza": resultado[0]['score'],
18        }
19    }

```

A continuación, se muestra dos evaluaciones hechas por el modelo.

```

1 {
2     "mensaje": "Clasificación completada.",
3     "resultado": {
4         "texto": "Silencio por favor",
5         "etiqueta": "no_ofensivo",
6         "confianza": 0.9671836495399475
7     }
8 }
9
10 {
11     "mensaje": "Clasificación completada.",
12     "resultado": {
13         "texto": "Calla idiota",

```

```

1         "etiqueta": "ofensivo",
2         "confianza": 0.9985875063374023
3     }
4 }

```

Capítulo 10

Evaluación Económica Financiera

10.1. Estimación del Alcance

El presente proyecto tiene como objetivo ofrecer un servicio de detección automática de lenguaje ofensivo en redes sociales y plataformas digitales, haciendo uso de modelos basados en arquitecturas Transformers. El servicio está diseñado para ser integrado principalmente por medios digitales —como portales de noticias y diarios en línea— que actualmente han restringido o eliminado la funcionalidad de comentarios por dificultades en su moderación. Asimismo, se proyecta como una solución viable para medios televisivos que requieren mostrar comentarios del público en transmisiones en vivo, garantizando previamente su moderación.

El valor agregado del servicio radica en su capacidad para filtrar, en tiempo real, contenido ofensivo o inapropiado proveniente de usuarios, asegurando que las interacciones públicas cumplan con estándares de respeto y convivencia digital. Esta funcionalidad permitirá a los medios:

- Reactivar espacios de comentarios sin temor al contenido ofensivo.
- Mostrar en vivo interacciones del público en emisiones televisivas con moderación automática.
- Ofrecer entornos seguros en sus propias plataformas para fomentar la participación del público.

A futuro, se contempla la expansión del servicio hacia canales de transmisión en línea (como Kick) y comunidades virtuales (como foros especializados o aplicaciones de mensajería grupal), donde el volumen y la inmediatez de los mensajes hacen indispensable una moderación automatizada.

10.2. Costos de Operación

10.2.1. Mano de Obra Directa

Para la etapa inicial del proyecto se contempla una estructura mínima de personal. Esta decisión busca optimizar recursos sin comprometer la calidad funcional del MVP. Conforme se validen hipótesis del mercado y aumente la base de usuarios, se contempla incorporar personal adicional.

Partiendo desde un equipo de desarrollo conformado por:

- **Desarrollador Full Stack:** Se encarga tanto del backend (API de detección) como del frontend (extensión, panel), integrando la funcionalidad del modelo y las interfaces.
- **Especialista DevOps:** Administra la infraestructura en la nube, automatiza los despliegues y garantiza la seguridad, escalabilidad y disponibilidad del sistema.

Y llegando hasta la agregación de los siguientes cargos:

- **Científico/a de Datos:** Encargado/a del diseño, entrenamiento y mejora continua del modelo de clasificación de lenguaje ofensivo, así como del análisis de métricas y validación del rendimiento.
- **Ingenieros/as de Software (2):** Responsables del desarrollo y mantenimiento del backend (API de detección), frontend (interfaz y extensión) e integraciones con plataformas de terceros.
- **Asistente de Soporte Técnico (1):** Brinda atención a los usuarios del servicio, realiza pruebas funcionales, monitorea el sistema y apoya en tareas operativas y de documentación.

A continuación se muestra la evolución de las planillas.

Figura 10.1: Mano de obra directa año 1 - Medio Tiempo **[Elaboración Propia]**

Figura 10.2: Mano de obra directa año 2 - Medio Tiempo **[Elaboración Propia]**

Figura 10.3: Mano de obra directa año 3 - Medio Tiempo **[Elaboración Propia]**

Figura 10.4: Mano de obra directa año 4 - Tiempo Completo **[Elaboración Propia]**

Figura 10.5: Mano de obra directa año 5 - Tiempo Completo **[Elaboración Propia]**

Figura 10.6: Mano de obra directa año 6 - Tiempo Completo **[Elaboración Propia]**

10.2.2. Costos Indirectos

Los costos indirectos comprenden aquellos gastos no directamente atribuibles a la mano de obra, pero indispensables para garantizar el funcionamiento continuo y seguro del servicio. Su comportamiento está estrechamente relacionado con la evolución del equipo técnico y del volumen de usuarios atendidos.

A medida que se incorporan nuevos perfiles y crece la base de clientes, se incrementan proporcionalmente ciertos rubros como el uso de servicios en la nube, la necesidad de herramientas de monitoreo, y los servicios de apoyo administrativo y legal.

- Energía Eléctrica.
- Suministro de Agua.
- Herramientas de Servicio.
- Depreciación Mobiliario.

Figura 10.7: Costos de Energía Eléctrica **[Elaboración Propia]**

Figura 10.8: Costos de Herramientas de Servicio **[Elaboración Propia]**

Figura 10.9: Costos Indirectos **[Elaboración Propia]**

10.3. Gastos Administrativos y Comerciales

10.3.1. Gastos Administrativos

Los gastos administrativos incluyen los costos asociados al funcionamiento interno de la organización, estos se muestran en la Figura 10.10

Figura 10.10: Gastos Administrativos **[Elaboración Propia]**

10.3.2. Gastos de Venta

Los gastos de ventas y marketing están enfocados en posicionar el servicio de detección de lenguaje ofensivo ante los medios digitales, televisivos y futuros socios estratégicos, además de otros gastos varios. Observar la Figura 10.11

Figura 10.11: Gastos Financieros **[Elaboración Propia]**

10.4. Costos Totales

Los costos totales del servicio comprenden la suma de todos los egresos necesarios para el desarrollo, operación, administración, promoción y sostenimiento financiero del proyecto. Esta agrupación permite tener una visión integral del esfuerzo económico requerido para mantener en funcionamiento el servicio de detección de lenguaje ofensivo en redes sociales.

A continuación, en la Figura 10.14 se presenta un resumen de los principales componentes de costo anual, considerando la estructura de personal definida, los costos indirectos proyectados, los gastos administrativos, comerciales y financieros estimados a partir del primer año de operación.

Figura 10.12: Costo Total del Servicio **[Elaboración Propia]**

10.5. Proyección a la inversión

10.5.1. Estimación de la Inversión Total

Para el inicio de las operaciones se ha estimado hacer una inversión total de S/ 18,450.00 los cuales cubrirían la compra de los equipos para cada equipo del proyecto.

El equipo de desarrollo necesita equipos con alta GPU para poder entrenar modelos inteligentes, Debido a este requerimiento se entiende porque el las computadoras personales resultan más costosas que la de los demás equipos.

Figura 10.13: Mobiliario de Administración **[Elaboración Propia]**

Figura 10.14: Mobiliario de Desarrollo **[Elaboración Propia]**

Figura 10.15: Mobiliario de Ventas **[Elaboración Propia]**

10.5.2. Depreciación total de activos tangibles

Dentro de la inversión inicial, los activos tangibles —principalmente los equipos tecnológicos— están sujetos a depreciación contable, según el método de línea recta. Se estima una vida útil de 6 años, considerando la rapidez de obsolescencia en entornos tecnológicos. Los detalles se muestran en la Figura 10.14

Figura 10.16: Depreciación de Activos tangibles **[Elaboración Propia]**

10.5.3. Plan de Inversión y Capital de Trabajo

Para realizar el plan de inversión tomamos en cuenta tres aspectos fundamentales: el total de nuestros activos fijos (mobiliario y equipos que deben estar incluidos en nuestras depreciaciones). El capital de trabajo necesario para comenzar a trabajar y los activos nominales.

En la Figura 10.19 se determina cuánto será el dinero que se debe gestionar como financiamiento y el que debe invertirse por los socios del proyecto o el inversionista. Los fondos de financiamiento son los que se utilizan para el cálculo de los gastos financieros en la Figura 10.13

Figura 10.17: Plan de Inversión [Elaboración Propia]

El cálculo del capital de trabajo dependerá de muchos factores como es el tiempo en que la empresa

tardará en comenzar a recibir efectivo propio de la inversión. Para ello tomaremos tantos factores como sean necesarios al proyecto, además restamos el porcentaje de las ventas de contado por ser el dinero que ya estamos recibiendo.

De acuerdo a la estructura del plan de inversión para la producción del servicio mostrado en la Figura 10.19, necesitamos un monto total de S/ 21,154.29, de los cuales el 69.07%, es decir aproximadamente S/25,125.67 corresponde a fondos propios de la sociedad y el 30.93 % restante debe ser cubierto por el sistema financiero mediante una Operación de Leasing.

El Leasing debe ser entendido como una operación de carácter financiero que consiste en la adquisición por parte la entidad financiera del equipamiento y la infraestructura y la cesión simultánea de uso durante un período de tiempo determinado que en nuestro caso es de seis años, a un precio que se distribuye en cuotas periódicas.

10.5.4. Balance de Apertura

El Balance mostrado en la Figura 10.20 se elabora en base al Plan de Inversión de la Figura 10.19; caja y bancos es igual al capital de trabajo necesitado para iniciar operaciones. El pasivo es igual al saldo del financiamiento: se toma como pasivo a corto plazo el importe del primer pago a capital según la forma de pago escogida; cuota nivelada o cuota de saldos insolutos. En este proyecto se decidió por la cuota nivelada Figura 10.13. El pasivo a largo plazo sería la diferencia entre lo que se tiene que pagar en este año y el importe total del financiamiento. El patrimonio será igual al total de activo fijo, es decir, lo que hemos invertido en el proyecto.

Figura 10.18: Balance de Apertura [Elaboración Propia]

10.6. Proyección de los Ingresos

La estimación de ingresos del proyecto parte de un modelo de negocio basado en el cobro por consumo, mediante una tarifa por cada mil mensajes procesados (requests). Esta

modalidad permite a los medios digitales, televisivos y otros futuros clientes contratar el servicio de detección de lenguaje ofensivo con flexibilidad y en función del volumen real de uso, lo cual favorece su adopción progresiva.

Figura 10.19: Proyección de ingresos **[Elaboración Propia]**

En la Figura 10.22 se muestra el porcentaje de ventas al contado y el nivel de ventas a crédito. Se observa que se está estimando que solo el 5 % de las ventas tendrán cobros al contado y el 95 % será al crédito.

Figura 10.20: Ventas al contado y al crédito **[Elaboración Propia]**

En la Figura 10.23 se observa el nivel de ventas al contado y la recuperación de las cuentas por cobrar, que al sumar totaliza el nivel de ingresos de efectivo que tendrá en proyecto.

Figura 10.21: Determinación de Ingresos Efectivo **[Elaboración Propia]**

10.7. Evaluación Financiera

10.7.1. Estado de Pérdidas y Ganancias

En la Figura 10.24 se muestra el estado de resultados proyectado hasta el año 6 del proyecto.

Figura 10.22: Estado de Resultados **[Elaboración Propia]**

10.7.2. Presupuesto caja y flujo de caja

En el presupuesto de caja para el año 0 interviene el monto de los fondos propios, el financiamiento para conocer el total de los ingresos, para conocer a su vez el total de los egresos, la compra de activos fijos y activos Nominales (vienen de la Figura 10.19). En dicha tabla encontramos dos valores: total ingresos y total egresos que se restan para obtener el flujo de efectivo que será el saldo final del año 0.

Para los siguientes años se hace una estimación de los egresos e ingresos. Observar la Figura 10.25.

Figura 10.23: Presupuesto Caja **[Elaboración Propia]**

10.7.3. Balance General Proyectado

10.7.4. Activos

El Año 0 es igual al balance de apertura (Figura 10.20). El activo circulante lo componen; caja y banco que surge del saldo final del presupuesto de caja (Figura 10.25), cuentas por cobrar (Figura 10.22). La suma de estos tres elementos da como resultado el total de los activos circulantes.

Para el total de activo fijo del año 1 va a permanecer igual que el año 0, pero en el año 1 se coloca la suma de todas las depreciaciones para ser restadas en el total de activo fijo neto. En los años subsiguientes se va restando la parte de depreciación correspondiente a cada activo.

Para los activos nominales es el mismo procedimiento pero con la variante que aquí se utiliza, la amortización de estos activos. La suma de los totales de estos activos nos da como resultado el total de

activo en cada año respectivamente.

10.7.5. Pasivos

El pasivo circulante lo componen las sumas de Préstamos a corto plazo, que corresponde al primer pago de abono capital (Figura 10.13), e impuesto a la renta que se calculó en el estado de resultado (Figura 10.24).

El pasivo a largo plazo es el préstamo a largo plazo que se calcula de la siguiente forma para cuota nivelada: el saldo del año en evaluación (Figura 10.24) menos préstamo.

El patrimonio lo conforman la suma de: patrimonio que es el mismo del balance de apertura en todos los años, utilidad a distribuir del estado de resultados, reserva legal y la utilidad acumulada, que es la suma de la utilidad a distribuir del año anterior más la utilidad acumulada de ese mismo año anterior.

El balance general proyectado semuestra en la Figura 10.26.

Figura 10.24: Balance General Proyectado **[Elaboración Propia]**

10.7.6. Análisis de los indicadores financieros de rentabilidad: VAN, TIR, IR

Flujo de Efectivo

Se elabora en base a los datos obtenidos en el presupuesto de caja (Figura 10.25). Primero colocamos el valor de la inversión que viene del plan de inversión (Figura 10.19). Para conocer el flujo neto de efectivo restamos el flujo de ingresos del flujo de egresos y en el año 6 sumamos la liquidación más cuentas x cobrar (Figura 10.26), liquidación inventarios finales (Figura 10.26) y el valor de salvamento (Figura 10.18) menos los pasivos circulantes (balance proyectado año 10 Tabla 35). Observar la (Figura 10.27)

Figura 10.25: Flujo Neto de Efectivo **[Elaboración Propia]**

Tasa de Corte

Primero encontramos el costo de capital para ello necesitamos conocer cuánto representa el total de nuestra inversión respecto del financiamiento que utilizaremos 14.91 % y 85.09 % respectivamente y el valor de la tasa máxima a la cual podríamos invertir los fondos propios en el sistema bancario o financiero y la tasa mejor a la que lograríamos conseguir el financiamiento del préstamo, 6 % y 12 % respectivamente. Todo esto se resume en la Figura 10.28

Figura 10.26: Costo de Capital [Elaboración Propia]

Valor Actual Neto VAN

El valor actual neto responde a la siguiente fórmula en Excel =VAN(tasa de corte, flujo año1, flujo año2, flujo año3, flujo año4, flujo año5, flujo año6).

Periodo de Recuperación

El análisis del periodo de recuperación utilizando flujos descontados permite determinar en qué momento el proyecto logra recuperar la inversión inicial considerando el valor del dinero en el tiempo. En este caso, la inversión inicial asciende a S/ 21,154.29. Al descontar los flujos de caja netos proyectados para cada año, se observa que el acumulado aún es negativo al finalizar el segundo año. No obstante, en el tercer año, el flujo descontado (S/ 99,829.15) permite cubrir el saldo pendiente, alcanzando un valor acumulado positivo. Mediante interpolación, se estima que el punto de equilibrio ocurre a los 2.79 años. Esto significa que el proyecto recupera su inversión inicial a través de los flujos netos descontados aproximadamente entre el segundo y tercer año de operación, lo cual refleja una recuperación relativamente rápida considerando la naturaleza tecnológica del servicio.

Figura 10.27: Valor Neto Actual y Periodo de Recuperación [Elaboración Propia]

Tasa Interna de Retorno

La tasa interna de retorno se calcula en Excel así =TIR (celda de la inversión en negativo: último flujo) =IRR(A1:A5)

Figura 10.28: Tasa interna de retorno [Elaboración Propia]

Índice de Rentabilidad

El índice de Rentabilidad es la suma de los flujos descontados entre el valor de la inversión:

Figura 10.29: Índice de Rentabilidad **[Elaboración Propia]**

10.7.7. Viabilidad Económica y Financiera

El análisis de los diversos datos estudiados a lo largo del capítulo nos permite concluir que el proyecto “Detección de Lenguaje Ofensivo usado en Redes Sociales empleando modelos Transformers” presenta una viabilidad económica y financiera favorable, especialmente a mediano y largo plazo.

A pesar de que el primer y segundo año presentan un desfase entre ingresos y costos operativos, propio de una etapa de inversión intensiva y posicionamiento, la progresión proyectada muestra un crecimiento sostenido en la facturación que permite cubrir los costos totales a partir del tercer o cuarto año. Esto implica un horizonte razonable para alcanzar el punto de equilibrio financiero.

Además, de acuerdo con el análisis de los estados financieros proyectados de la empresa (que incorporan estos elementos) y el de los indicadores derivados a partir de ellos, es posible afirmar que el proyecto es una inversión rentable, con lo cual se asegura la viabilidad del negocio.

Capítulo 11

Normas Técnicas

11.1. Normas de Desarrollo y Documentación de Software

Se ha seguido un enfoque estructurado de desarrollo, utilizando buenas prácticas de codificación y organización del código fuente. En particular:

- PEP 8 – Guía de estilo para Python, aplicable al código implementado para el entrenamiento y despliegue del modelo [19].

11.2. Normas sobre gestión de datos

El uso del corpus OffendES, aunque público, sigue prácticas de manejo ético de datos. Por tanto, se han aplicado normas como:

- ISO/IEC 27001 – Gestión de seguridad de la información [20].

11.3. Normas sobre modelos de IA

En el desarrollo del modelo de lenguaje ofensivo se ha considerado:

- Guía ética para inteligencia artificial de la UNESCO (2021), enfocada en la transparencia, no discriminación y trazabilidad [21].

Capítulo 12

Conclusiones y Trabajos Futuros

12.1. Conclusiones

El presente proyecto ha abordado el desarrollo de un sistema de detección de lenguaje ofensivo en español, utilizando modelos de lenguaje basados en transformers, con el fin de responder a una necesidad creciente en los entornos digitales actuales. A través del uso del corpus OffendES y del modelo BETO, se logró construir una arquitectura de clasificación que permite identificar con buena precisión comentarios ofensivos dentro de contextos reales de comunicación, como los que se producen en redes sociales o medios digitales.

Durante el desarrollo se evidenció que, si bien existen herramientas avanzadas utilizadas por grandes plataformas internacionales, muchas de estas soluciones no están disponibles para terceros o no contemplan adecuadamente el idioma español. Esta situación reafirma la relevancia y oportunidad del presente trabajo, especialmente al enfocarse en un mercado objetivo como el de los medios de comunicación digitales, los cuales requieren soluciones ágiles y confiables para gestionar comentarios del público en sitios web y transmisiones en vivo.

El sistema propuesto no solo permite clasificar comentarios de manera eficiente, sino que también es adaptable a diferentes plataformas y escalable según la demanda. Se ha demostrado la viabilidad técnica del modelo y se ha propuesto un esquema de despliegue funcional, además de una evaluación económica que sustenta el potencial de este proyecto como servicio en el mercado.

12.1.1. Trabajos Futuros

A partir de los resultados obtenidos, se plantean las siguientes líneas de trabajo para fortalecer y extender el alcance del sistema:

- **Ampliación del corpus:** Incorporar nuevos datasets multitemáticos o propios, que reflejen mejor la variabilidad del lenguaje ofensivo en otras plataformas como foros, chats en vivo, videojuegos y transmisiones.
- **Clasificación multicategoría:** Extender la arquitectura del modelo para no solo detectar la presencia de lenguaje ofensivo, sino también categorizarlo según su tipo (insultos, discurso de odio, violencia de género, etc.).

- **Implementación de una interfaz web o API pública:** Permitir el uso del modelo por parte de terceros a través de una API REST o una extensión de navegador, facilitando la integración con otros servicios.
- **Adaptación a tiempo real:** Optimizar el rendimiento del modelo para implementaciones que requieran respuesta inmediata, como transmisiones en vivo o bots de moderación en plataformas como Discord, Telegram o transmisiones televisivas.
- **Evaluación en escenarios reales:** Realizar pruebas con medios de comunicación locales u organizaciones interesadas en moderar sus espacios de participación, para validar el sistema en condiciones reales de operación.
- **Refinamiento lingüístico y cultural:** Mejorar la detección tomando en cuenta variaciones regionales del español y contextos culturales que puedan afectar la interpretación de lo que es ofensivo.

Apéndice A

Anexos

A.1. Funciones para Datos Tokenizados

A continuación, se muestran funciones adicionales del proyecto para con los datos tokenizados:

A.1.1. Tokenización de los datos

Listing A.1. Función para Tokenizar los Datos

```
1 def save_tokenized_data(df_dict, max_length=None):
2     """
3     Convierte los datos tokenizados (diccionario de arrays) a DatasetDict de
4     Hugging Face
5     y los guarda en disco.
6     """
7
8     tokenizer=load_tokenizer()
9
10    hf_datasets = DatasetDict()
11
12    for subset, df in df_dict.items():
13        # Tokenizar los comentarios
14        tokenized = tokenizer(
15            df["comment"].tolist(),
16            padding=True,
17            truncation=max_length is not None,
18            max_length=max_length,
19            return_tensors="np"
20        )
21
22        # Crear Dataset
23        hf_dataset = Dataset.from_dict({
24            "input_ids": tokenized["input_ids"],
25            "attention_mask": tokenized["attention_mask"],
26            "labels": np.array(df["label"])
27        })
28
```

```
29 hf_datasets[subset] = hf_dataset
```

```
1 tokenize_path = Path(os.environ.get("TOKENIZE_PATH"))
2 tokenize_path.mkdir(parents=True, exist_ok=True)
3 hf_datasets.save_to_disk(tokenize_path)
4
5 return {
6     "message": "Tokenización de la data exitosa",
7     "ruta_de_guardado": str(tokenize_path)
8 }
```

A.2. Muestra de un Dato Tokenizado

A continuación, se muestra la función que mostró un ejemplo de dato tokenizado en el capítulo 9, además de un segundo ejemplo de salida.

Listing A.2. Función para mostrar un Dato Tokenizado

```
1 def show_tokenized_example(subset="train", idx=None):
2     """
3     Muestra los datos tokenizados.
4     """
5
6     # Cargar el DatasetDict desde disco
7     tokenize_path = Path(os.environ.get("TOKENIZE_PATH"))
8     hf_datasets = DatasetDict.load_from_disk(tokenize_path)
9
10    dataset = hf_datasets[subset]
11    if idx is None:
12        idx = random.randint(0, len(dataset) - 1)
13
14    example = dataset[idx]
15    tokenizer = load_tokenizer()
16    text = tokenizer.decode(example['input_ids'], skip_special_tokens=True)
17    tokens = tokenizer.convert_ids_to_tokens(example['input_ids'])
18
19    return {
20        "message": "Ejemplo de dato tokenizado",
21        "indice": idx,
22        "texto_decodificado": text,
23        "tokens": tokens[:10],
24        "input_ids": example['input_ids'][:5],
25        "attention_mask": example['attention_mask'][:5],
26        "etiqueta": example['labels']
27    }
```

```
1 {
2   "message": "Ejemplo de dato tokenizado",
3   "índice": 3701,
4   "texto decodificado": "Sinceramente... Después de ver el proceso creativo
5   del logo de totalmente horrible lmao",
6   "tokens": [
7     "[CLS]",
8     "Sinceramente",
9     ".",
10    ".",
11    ".",
12    "Después",
13    "de",
14    "ver",
15    "el",
16    "proceso"
17  ],
18  "input_ids": [
19    4,
20    27235,
21    1009,
22    1009,
23    1009
24  ],
25  "attention_mask": [
26    1,
27    1,
28    1,
29    1,
30    1
31  ],
32  "etiqueta": 0
33 }
```

A.3. Funciones para el Modelo

A continuación, se muestran funciones adicionales del proyecto para con el modelo entrenado:

A.3.1. Entrenamiento del Modelo

Listing A.3. Función para Entrenar el Modelo

```
1 def train_model():
2     """
3     Ejecuta el entrenamiento
4     """
5
6     trainer=config_trainer()
7
8     trainer.train()
9
10    best_model_path = Path(os.environ.get("TRANSFORMER_PATH")) / "best_model"
11    trainer.save_model(best_model_path)
12
13    return {
14        "message": "Modelo entrenado y guardado con éxito.",
15        "ruta del modelo": str(best_model_path)
16    }
```

A.3.2. Métricas del Modelo

Listing A.4. Función para Obtener Métricas del Modelo

```
1 def load_metrics(dataset_type="test"):
2     """
3     Carga las métricas guardadas desde disco.
4     """
5
6     metrics_path = Path(os.environ.get("TRANSFORMER_PATH")) / f"metrics_{
dataset_type}.json"
7
8     if not metrics_path.exists():
9         raise FileNotFoundError(f"No se encontró el archivo de métricas en: {
metrics_path}")
10
11    with open(metrics_path, "r") as f:
12        metrics = json.load(f)
13
14    return {
15        "message": f"Métricas cargadas desde {dataset_type}.",
16        "métricas": metrics
17    }
```

A.3.3. Pipeline del Modelo

Listing A.5. Función para Guardar un Pipeline del Modelo

```
1 def save_pipeline():
2     """
3     Guarda el pipeline listo para producción (modelo + tokenizador)
4     """
5
6     model_path = Path(os.environ.get("TRANSFORMER_PATH")) / "best_model"
7     tokenizer = tok.load_tokenizer()
8
9     # Crear pipeline
10    classifier = pipeline(
11        "text-classification",
12        model=str(model_path),
13        tokenizer=tokenizer
14    )
15
16    # Guardar pipeline
17    pipeline_path = Path(os.environ.get("TRANSFORMER_PATH")) / "pipeline"
18    classifier.save_pretrained(pipeline_path)
19
20    return {
21        "message": "Pipeline guardado con éxito.",
22        "ruta del pipeline": str(pipeline_path)
23    }
```

A.4. Ejemplos de textos clasificados

A continuación, se muestran salidas de textos clasificados por la función *classifier* vista en el capítulo 9.

```
1 {
2     "mensaje": "Clasificación completada.",
3     "resultado": {
4         "texto": "Impresora negra",
5         "etiqueta": "no ofensivo",
6         "confianza": 0.9693416357040405
7     }
8 }
```

```
1 {  
2   "mensaje": "Clasificación completada.",  
3   "resultado": {  
4     "texto": "calla negra",  
5     "etiqueta": "ofensivo",  
6     "confianza": 0.9984779953956604  
7   }  
8 }
```

Bibliografía

- [1] Preply. Hate speech and bullying in video games, 2022. Accedido el 6 de abril de 2025.
- [2] D. Hickey et al. X under musk’s leadership: Substantial hate and no reduction in inauthentic activity. *PLOS ONE*, 20(2):e0313293, 2025.
- [3] Flor Miriam Plaza-del Arco et al. Offendes: A new corpus in spanish for offensive language research. In Ruslan Mitkov and Galia Angelova, editors, *Proceedings of the International Conference on Recent Advances in Natural Language Processing (RANLP 2021)*, pages 1096–1108, Held Online, September 2021. INCOMA Ltd.
- [4] Fundación MAPFRE and Universidad de Deusto. El lado oscuro de las redes sociales: efectos de los comentarios negativos en la salud mental, 2023. Consultado el 9 de abril de 2025.
- [5] PantallasAmigas. Análisis sobre los efectos de los comentarios negativos en redes sociales y otros espacios digitales, 2024. Accedido en abril de 2025.
- [6] Business Research Insights. Tamaño y tendencias del mercado de moderación de contenido automatizado, 2032, 2024. Consultado en abril de 2025.
- [7] Business Research Insights. Tamaño y tendencias del mercado de soluciones de moderación de contenido, 2032, 2024. Accedido en abril de 2025.
- [8] SNS Insider. Content moderation services market forecast 2032, 2024. Consultado en abril de 2025.
- [9] Perspective API. Investigación sobre el aprendizaje automático, 2025. Accedido el 15 de abril de 2025.
- [10] Jigsaw. Google’s jigsaw announces toxicity-reducing api, perspective, is processing 500m requests daily, 2021. Consultado en abril de 2025.
- [11] Meta. Cómo funciona la tecnología de detección de infracciones | centro de transparencia, 2025. Accedido el 15 de abril de 2025.
- [12] Microsoft. Azure ai services: Content moderator documentation, 2025. Accedido el 15 de abril de 2025.
- [13] Twitch Safety. Herramientas de chat | seguridad en twitch, 2025. Accedido el 15 de abril de 2025.
- [14] Discord Support. Automod faq, 2025. Accedido el 23 de abril de 2025.

- [15] Telegram. Bots: An introduction for developers, 2025. Accedido el 23 de abril de 2025.
- [16] IBM. ¿qué es un modelo transformer?, 2025. Consultado el 28 de abril de 2025.
- [17] Ashish Vaswani et al. Attention is all you need. In *Advances in Neural Information Processing Systems*, volume 30. Curran Associates, Inc., 2017.
- [18] fmplaza. prompting_hate_speech, 2025. Consultado el 14 de mayo de 2025.
- [19] Python Software Foundation. Pep 8 – style guide for python code, 2025. Consultado en junio de 2025.
- [20] International Organization for Standardization. Iso/iec 27001:2022 – information security, cybersecurity and privacy protection – information security management systems – requirements, 2022. Consultado en junio de 2025.
- [21] UNESCO. ética de la inteligencia artificial, 2024. Consultado en junio de 2025.