

Modelo Híbrido RSSI–Orientación con Mecanismos de Atención para Localización Indoor y Activación Contextual en Museos

Hybrid RSSI–Orientation Attention Model for Indoor Localization and Contextual Activation in Museums

Jhunion Eduardo Guevara Lázaro^{*1}, Yury Tello Canchapoma^{*2}

^{*}Universidad Nacional de Ingeniería
 Lima, Perú

¹jguevaral@uni.pe

²yury.tello.c@uni.edu.pe

Recibido: AAAA-MM-DD ; Aceptado: AAAA-MM-DD

Resumen—Indoor localization in museums and cultural spaces requires not only identifying the room or sector where a visitor is located, but also estimating which artwork the visitor is probably observing. GPS is unreliable indoors, and Wi-Fi/BLE RSSI measurements are affected by multipath propagation, obstacles, temporal variations, transmission power and device heterogeneity. This paper reformulates a previous RSSI fingerprinting baseline into a hybrid RSSI–orientation proposal for museum-oriented contextual activation. The specific contribution is a model and proof-of-concept protocol that combines RSSI-based sector classification with smartphone orientation, represented through angular features, to infer the most likely artwork or observation zone. A public BLE RSSI dataset with 8400 samples, 28 sectors and three transmission power levels is used as a reproducible baseline to quantify the limitations of RSSI-only localization. Since this dataset does not contain inertial or orientation measurements, the orientation component is formalized as an extension to be validated in a 6–8 sector museum room. The proposed framework therefore distinguishes between executed baseline experiments and the author’s own RSSI–orientation extension, preserving methodological transparency while aligning the paper with the intended museum application.

Keywords: indoor localization; BLE; RSSI fingerprinting; smartphone orientation; attention mechanisms; contextual activation; museums.

Resumen— La localización indoor en museos y espacios culturales no solo requiere identificar la sala o sector donde se encuentra el visitante, sino también estimar qué obra está probablemente observando. El GPS no resulta confiable en interiores y las mediciones RSSI Wi-Fi/BLE son afectadas por propagación multitrayecto, obstáculos, variaciones temporales, potencia de transmisión y heterogeneidad de dispositivos. Este artículo reformula una línea base previa de fingerprinting RSSI hacia una propuesta híbrida RSSI–orientación para activación contextual en museos. La contribución específica consiste en un modelo y protocolo de prueba de concepto que combina clasificación de sector basada en RSSI con orientación del smartphone, representada mediante características angulares,

para inferir la obra o zona de observación más probable. Se utiliza un dataset público BLE RSSI con 8400 muestras, 28 sectores y tres niveles de potencia como línea base reproducible para cuantificar las limitaciones de la localización basada solo en RSSI. Dado que dicho dataset no contiene mediciones inerciales ni de orientación, el componente de dirección se formaliza como extensión a validar en una sala museográfica de 6–8 sectores. De este modo, el marco propuesto distingue entre experimentos ya ejecutados y la extensión propia RSSI–orientación, preservando transparencia metodológica y alineando el artículo con la aplicación museográfica prevista.

Palabras clave: localización indoor; BLE; fingerprinting RSSI; orientación del smartphone; mecanismos de atención; activación contextual; museos.

I. INTRODUCCIÓN

Los museos y espacios culturales incorporan aplicaciones móviles e Internet de las Cosas para ofrecer recorridos guiados, activación de audios, información de salas, descripciones de objetos y recursos multimedia contextualizados. Para que estos servicios funcionen de manera adecuada, el sistema debe reconocer con precisión la ubicación indoor del dispositivo del visitante. A diferencia de los escenarios exteriores, el uso de GPS en interiores resulta limitado por la baja disponibilidad de señal satelital. En consecuencia, Wi-Fi y Bluetooth Low Energy (BLE) se han consolidado como alternativas de bajo costo y amplia disponibilidad para estimar ubicaciones a partir de señales de radiofrecuencia [1]–[4].

El problema central es que las señales Wi-Fi/BLE presentan variabilidad por inestabilidad del RSSI, propagación multitrayecto, obstrucciones, movilidad de personas, heterogeneidad de dispositivos y variaciones temporales del entorno. Estudios sobre BLE muestran que el canal indoor y el desvanecimiento multitrayecto afectan directamente la estimación de distancia a partir de RSS [5], [6]. En dispositivos Wi-

Fi/BLE diversos, estas condiciones pueden producir errores de clasificación de sector, degradación del error espacial y activaciones contextuales imprecisas o tardías. Por ello, el problema de estudio se formula como la deficiente precisión de localización indoor en dispositivos Wi-Fi/BLE diversos en museos y espacios culturales, 2026.

En una sala de museo, además, el sector estimado no siempre basta para activar el contenido correcto: un visitante puede estar dentro del mismo sector físico y mirar obras distintas, o ubicarse entre dos sectores con objetos cercanos. Por ello, este trabajo introduce como aporte propio la incorporación de la dirección u orientación del smartphone como señal complementaria al RSSI. La intuición es que el RSSI aproxima la zona probable del usuario, mientras que el rumbo del dispositivo ayuda a inferir hacia qué obra o panel se dirige su atención.

La variable independiente de esta investigación es un modelo híbrido de aprendizaje profundo con mecanismos de atención que fusiona RSSI y orientación del smartphone. La variable dependiente es la precisión de localización indoor, operacionalizada en tres dimensiones: exactitud métrico-espacial, robustez del sistema y pertinencia del servicio. Esta reformulación desplaza el foco desde la calidad general del servicio de guía virtual hacia el desempeño de localización y activación contextual como capacidad técnica medible.

La literatura reciente evidencia que el fingerprinting basado en aprendizaje automático puede mejorar el posicionamiento indoor a partir de vectores RSSI [3], [7], [8]. Además, las redes neuronales con mecanismos de atención han sido utilizadas para enfrentar variaciones temporales y heterogeneidad entre smartphones [9], [10]. En esa línea, el objetivo general del presente trabajo es proponer y evaluar una base experimental para un modelo híbrido RSSI–orientación con mecanismos de atención que permita mejorar la localización indoor por sectores y la activación contextual de obras en museos y espacios culturales.

II. MARCO TEÓRICO

II-A. Localización Indoor con Wi-Fi y BLE

La localización indoor puede abordarse mediante Wi-Fi, BLE, UWB, RFID, sensores inerciales, visión computacional, señales acústicas o enfoques híbridos [11]–[16]. En escenarios culturales, Wi-Fi y BLE son relevantes porque pueden aprovechar infraestructura existente o beacons de bajo consumo. Sin embargo, la intensidad de señal recibida (RSSI) es sensible a condiciones del entorno y no siempre presenta una relación estable con la distancia física.

Los enfoques de localización basados en RSSI suelen organizarse en dos grupos. El primero estima distancias mediante modelos de propagación y luego calcula la ubicación con triangulación o trilateración. El segundo utiliza fingerprinting: registra huellas RSSI en ubicaciones conocidas y entrena un modelo para clasificar o estimar posiciones a partir de nuevas mediciones. Este último enfoque resulta apropiado cuando existen sectores definidos, como salas, pasillos o zonas de interés en un museo. En aplicaciones de proximidad,

BLE también ha sido empleado para servicios contextuales y de activación por cercanía, lo que refuerza su pertinencia para recorridos culturales [17].

II-B. Orientación del Smartphone como Señal Contextual

Los sensores integrados en smartphones permiten complementar la localización por radiofrecuencia con información de orientación. En Android, la orientación del dispositivo puede estimarse a partir del acelerómetro y el sensor geomagnético, o mediante sensores de vector de rotación; el sensor de orientación clásico se encuentra obsoleto, por lo que se recomienda trabajar con sensores de posición y rotación disponibles en el marco actual de sensores [18]. En localización indoor, la fusión de beacons BLE con sensores inerciales de smartphone ha sido estudiada para mejorar estabilidad y continuidad de estimación [11], [19].

En el caso museográfico, la orientación no se propone como sustituto del RSSI ni como un sistema de navegación inercial completo. Su función es contextual: cuando el modelo estima el sector donde se encuentra el visitante, el rumbo del dispositivo puede ayudar a decidir qué obra, vitrina o panel se encuentra en la dirección de observación. Este enfoque es pertinente para salas con 6–8 sectores, donde el objetivo operativo no es obtener coordenadas centimétricas, sino activar contenido cultural correcto y oportuno.

II-C. Heterogeneidad de Dispositivos

La expresión dispositivos Wi-Fi/BLE diversos alude a la variación en hardware, antenas, sistemas operativos, tasas de muestreo, calibración y sensibilidad de recepción. Dos dispositivos ubicados en el mismo punto pueden reportar valores RSSI distintos, lo que degrada modelos entrenados con un único receptor. La heterogeneidad también se combina con cambios temporales del entorno, presencia de personas y modificaciones en la infraestructura. Por ello, la robustez del sistema debe evaluarse explícitamente y no inferirse solo desde la exactitud promedio. Esta necesidad coincide con trabajos que reportan diferencias de RSS entre dispositivos y proponen estrategias para mejorar la invariancia del modelo [8]–[10].

II-D. Aprendizaje Profundo y Mecanismos de Atención

Los algoritmos supervisados para fingerprinting indoor incluyen k vecinos más cercanos, máquinas de soporte vectorial, árboles, ensambles, redes neuronales, extreme learning machines y modelos de aprendizaje profundo [8], [20], [21]. En localización indoor basada en redes neuronales, Gerez et al. [2] muestran que la combinación de salidas de estimación de distancia puede incrementar la precisión respecto a métodos individuales. Ferrero-López et al. [4] también evidencian la utilidad de redes neuronales sobre fingerprinting BLE, incluyendo una fase de captura, filtrado y clasificación.

Los mecanismos de atención permiten ponderar dinámicamente las características más informativas de una entrada. En un vector RSSI, esta capacidad puede asignar mayor peso a los beacons o puntos de acceso más discriminativos y reducir

la influencia de señales ruidosas. Trabajos recientes como STELLAR y redes de atención multi-cabeza exploran esta idea para superar variaciones temporales y diferencias entre smartphones [9], [10], [22].

II-E. Síntesis del Estado del Arte

Los antecedentes revisados permiten identificar cinco tendencias relevantes para esta investigación. Primero, el fingerprinting Wi-Fi/BLE continúa siendo una alternativa práctica para espacios interiores porque no exige línea de vista y puede aprovechar infraestructura disponible [1], [3]. Segundo, el desempeño depende de la calidad de la huella RSSI, por lo que el filtrado, la reducción de dimensionalidad y la selección de características son pasos críticos [4], [7]. Tercero, la heterogeneidad de dispositivos y las variaciones temporales son problemas abiertos que afectan la generalización de los modelos [9], [10]. Cuarto, las soluciones híbridas con sensores inerciales, mapas, visión, audio, UWB o CSI pueden mejorar la cobertura y estabilidad, aunque incrementan complejidad de despliegue [11], [14], [15], [19]. Quinto, para aplicaciones museográficas, la pertinencia del contenido no depende solo del sector estimado, sino también de la dirección de observación del visitante; este punto abre el espacio para la propuesta RSSI–orientación desarrollada en este artículo.

III. MATERIALES Y MÉTODOS

III-A. Diseño Metodológico

La metodología se derivó de la matriz de consistencia y conservó su lógica causal: la variable independiente fue el modelo híbrido RSSI–orientación con mecanismos de atención y la variable dependiente fue la precisión de localización indoor y activación contextual en dispositivos Wi-Fi/BLE diversos. El estudio se planteó con enfoque cuantitativo, tipo aplicado, nivel correlacional-explicativo y diseño cuasiexperimental transversal. Fue cuasiexperimental porque comparó el desempeño de modelos base bajo escenarios controlados de potencia, planta y partición de datos; y fue transversal porque las mediciones RSSI disponibles correspondieron a una campaña de adquisición definida. La extensión con orientación se formula como prueba de concepto, ya que requiere una campaña propia de captura en sala museográfica.

El desarrollo metodológico tomó como referencia el esquema experimental de Gerez et al. [2]: primero se caracterizaron las señales de radiofrecuencia, luego se compararon métodos base, después se incorporó una red neuronal para mejorar la estimación y finalmente se verificó la mejora con indicadores de error. En el presente trabajo esa lógica se adaptó al problema de fingerprinting BLE por sectores y se extendió hacia una tarea museográfica: estimar el sector y seleccionar la obra observada. En la línea base ejecutada, cada registro se modeló como una huella RSSI $x = [B1, \dots, B6]$ y se predijo el sector indoor asociado. En la contribución propuesta, el vector se amplía con la orientación del smartphone para que la decisión contextual incorpore no solo dónde está el usuario, sino también hacia dónde dirige el dispositivo.



Figura 1. Diagrama de flujo de la metodología aplicada, desde la matriz de consistencia hasta la evaluación experimental.

El problema general de investigación se expresó como: ¿cómo influye un modelo híbrido RSSI–orientación con mecanismos de atención en la mejora de la localización indoor por sectores y la activación contextual de obras en museos y espacios culturales? La hipótesis general sostuvo que incorporar dirección del smartphone como variable contextual complementaria al RSSI puede mejorar la pertinencia del servicio, especialmente cuando existen varias obras dentro de una misma sala o zona. Los objetivos específicos de la matriz se operacionalizaron mediante tres dimensiones: exactitud métrico-espacial, robustez del sistema y pertinencia del servicio. El flujo metodológico seguido para pasar de la sistematización de la matriz a la experimentación reproducible se resume en la Fig. 1.

III-B. Población, Muestra y Alcance

La población teórica correspondió a registros de señales, orientación del smartphone y eventos de activación de dispositivos Wi-Fi/BLE diversos en museos y espacios culturales. Para la fase experimental ejecutada en este artículo, la muestra operativa se limitó a registros BLE RSSI recolectados con un smartphone en un entorno indoor universitario. Esta decisión mantuvo la coherencia con la matriz porque permitió evaluar preliminarmente la precisión de localización indoor, aunque delimitó el alcance: el dataset disponible no contiene orientación, Wi-Fi, múltiples dispositivos ni activación contextual real. Por ello, la dirección del celular se incorpora como extensión metodológica y protocolo de prueba de concepto.

III-C. Escenario Experimental y Muestra Operativa

Como base experimental inicial se consideró un conjunto de datos de fingerprinting BLE recolectado con seis beacons MOKO SMART H2 y un smartphone Xiaomi Mi 9T Pro en dos áreas interiores de la Escuela Superior de Ingeniería Informática de Albacete, Universidad de Castilla-La Mancha. El ambiente fue dividido en 28 sectores: 7 en una primera planta y 21 en planta baja. Para cada sector se registraron

aproximadamente 100 muestras por configuración de potencia de transmisión. La muestra operativa estuvo formada por 8400 registros, organizados en tres potencias de transmisión (-8 dBm, -4 dBm y 0 dBm) y en subconjuntos por planta.

La selección de este dataset respondió a la esencia de la sistematización: permitió pasar de la matriz de consistencia a una validación experimental concreta y medir cuánto puede lograrse con RSSI sin orientación. La exactitud métrico-espacial se estudió mediante predicción de sectores; la robustez se aproximó por cambios de potencia y separación por planta; y la pertinencia del servicio se analizó como activación contextual simulada a partir del sector estimado. Por tanto, el conjunto de datos no sustituyó la validación final en museos con dispositivos Wi-Fi/BLE diversos, pero sí permitió construir una línea base que justifica la extensión RSSI-orientación. Para favorecer la reproducibilidad, las rutas de archivos se reportaron desde la raíz del repositorio fuente BLE_RSSI_Indoor_Localization_Dataset/; por ejemplo, los CSV se ubicaron en data/.

Tabla I
RESUMEN DEL CONJUNTO DE DATOS BLE

Característica	Valor
Tecnología	BLE RSSI
Beacons	6 MOKO SMART H2
Receptor	Xiaomi Mi 9T Pro
Sectores	28 sectores interiores
Potencias	-8 dBm, -4 dBm y 0 dBm
Muestras	8400 muestras combinadas
Variables	B1–B6 y sector




Figura 2. Distribución general de sectores y beacons considerada para los experimentos de fingerprinting BLE.

III-D. Técnicas e Instrumentos

La técnica principal de recolección correspondió a la medición de huellas RSSI en puntos o sectores previamente

definidos. En la fase actual, los instrumentos operativos fueron los beacons BLE, el smartphone receptor, la sectorización del ambiente, los archivos CSV y los metadatos del dataset. Estos recursos se documentaron con rutas absolutas respecto al repositorio fuente: data/ para datos, metadata/ para metadatos, Notebooks/ para cuadernos reproducibles y documentation/ para la documentación técnica. El procesamiento se planteó mediante Python para preparación de datos, entrenamiento, validación y cálculo de métricas. En la fase de ampliación hacia museos, los instrumentos previstos fueron una aplicación móvil, beacons BLE, puntos de acceso Wi-Fi, sensores de orientación del smartphone, registros de activación contextual y fichas de observación estructurada. Esta separación permitió mantener consistencia con la matriz sin atribuir al dataset actual variables que todavía no contiene.

III-E. Variables, Dimensiones e Indicadores

La Tabla II resumió la operacionalización derivada de la matriz de consistencia. La variable independiente se caracterizó por complejidad del modelo y tiempo de inferencia. La variable dependiente, precisión de localización indoor, se evaluó mediante exactitud métrico-espacial, robustez del sistema y pertinencia del servicio. En correspondencia con el enfoque experimental del trabajo de referencia, cada dimensión se asoció a indicadores cuantificables y comparables entre modelos. Para evitar una sobreafirmación metodológica, la tabla distinguió entre indicadores medibles con el dataset BLE actual e indicadores que requieren una ampliación posterior de datos.

IV. MODELO PROPUESTO

El modelo propuesto se diseña como una arquitectura híbrida para museos: una primera etapa estima el sector indoor a partir de fingerprinting RSSI y una segunda etapa incorpora la orientación del smartphone para inferir la obra o zona de observación más probable. Su propósito no es estimar una distancia aislada entre emisor y receptor, sino apoyar una decisión contextual: qué contenido debe mostrarse en el celular del visitante. De este modo, se adapta la idea del trabajo de referencia [2]: en lugar de fusionar salidas de algoritmos de distancia, se fusionan fuentes RSSI y una señal de dirección del dispositivo para mejorar la pertinencia de la activación cultural.

IV-A. Representación de Entrada

Cada muestra RSSI se representa como $x_i^r = [r_{i1}, r_{i2}, \dots, r_{im}]$, donde m es el número de fuentes de radiofrecuencia observadas. En el dataset BLE actual, $m = 6$ y las fuentes corresponden a los beacons B1–B6. En la extensión prevista, el mismo vector puede incorporar puntos de acceso Wi-Fi, beacons BLE adicionales o variables auxiliares disponibles en una aplicación móvil. Las mediciones RSSI se estandarizan con los parámetros calculados en el conjunto de entrenamiento para evitar fuga de información hacia prueba.

La orientación del smartphone se representa mediante el rumbo horizontal o azimut θ_i . Para evitar la discontinuidad

Tabla II
 VARIABLES, DIMENSIONES E INDICADORES DE EVALUACIÓN

Variable	Dimensión	Indicadores medibles con el dataset BLE	Indicadores de ampliación RSSI–orientación
Modelo híbrido RSSI–orientación con mecanismos de atención	Complejidad del modelo	Número de parámetros, profundidad, tamaño del modelo RSSI	Incorporación de $\sin \theta$, $\cos \theta$, calidad de sensor y costo de despliegue móvil
	Tiempo de inferencia	Latencia promedio, inferencias por segundo	Latencia en aplicación móvil real con lectura BLE y sensores
Precisión de localización indoor	Exactitud métrico-espacial	Accuracy, F1 macro, matriz de confusión, error medio, RMSE	Error sobre plano real de museo y clasificación de 6–8 sectores
	Robustez del sistema	Degradación ante cambios de potencia y planta	Variación temporal, Wi-Fi y múltiples dispositivos
	Pertinencia del servicio	Activación contextual simulada por sector o zona	Exactitud de obra activada, falsas activaciones, error angular y recorridos de visitantes

Tabla III
 CORRESPONDENCIA ENTRE MATRIZ DE CONSISTENCIA Y VALIDACIÓN EXPERIMENTAL

Elemento de la matriz	Dimensión asociada	Validación con el dataset disponible
O.E. 1: mejorar la exactitud métrico-espacial	Exactitud métrico-espacial	Clasificación supervisada de sector con B1–B6; cálculo de accuracy, F1 macro, matriz de confusión y error aproximado por centroides de sector.
O.E. 2: mejorar la robustez del sistema	Robustez del sistema	Comparación entre potencias -8 dBm, -4 dBm y 0 dBm; entrenamiento en una potencia y prueba en otra; comparación por primera planta y planta baja.
Aporte propio: incorporar dirección del smartphone	Pertinencia del servicio	No medible con el dataset público porque no contiene orientación. Se formula como prueba de concepto RSSI–orientación para seleccionar obra observada.
O.E. 3: mejorar la pertinencia del servicio	Pertinencia del servicio	Evaluación indirecta mediante reglas de activación por sector o zona; validación futura con logs de app, orientación y obra activa.

entre 359° y 0° , el ángulo no se usa como valor crudo, sino como par circular:

$$o_i = [\sin(\theta_i), \cos(\theta_i)]. \quad (1)$$

La entrada híbrida queda entonces definida como:

$$x_i^h = [x_i^r, \sin(\theta_i), \cos(\theta_i), q_i], \quad (2)$$

donde q_i es una variable opcional de calidad o confiabilidad del sensor, por ejemplo la precisión reportada por el sistema operativo o una bandera de calibración. En la experimentación ejecutada solo se dispone de x_i^r ; por ello, x_i^h se reserva para la prueba de concepto en sala museográfica.

Para que el diseño sea compatible con señales ausentes o infraestructura heterogénea, cada fuente se convierte en un token:

$$z_j = W_e[\tilde{r}_j, a_j]^T + p_j, \quad (3)$$

donde $\tilde{r}_j$ es el RSSI normalizado de la fuente j , a_j es una máscara binaria de disponibilidad de señal, p_j es un embedding que identifica la fuente de radio y W_e es una matriz entrenable de proyección. En el dataset actual todas las fuentes BLE están definidas; sin embargo, la máscara permite que el modelo sea extensible a casos con puntos de acceso no detectados o dispositivos con distinta sensibilidad de recepción.

En la versión híbrida se consideran dos estrategias de fusión. La primera es fusión temprana, donde o_i se concatena al vector agregado antes del clasificador. La segunda es fusión tardía, donde el clasificador RSSI estima el sector y la orientación se emplea después para seleccionar la obra dentro del sector o en su vecindad. Para una prueba de concepto con 6–8 sectores, la fusión tardía es especialmente defendible porque separa la localización física de la decisión museográfica.

IV-B. Bloque de Atención

Los tokens $Z = [z_1, \dots, z_m]$ ingresan a un bloque de autoatención multi-cabeza. Para cada cabeza h , la atención se calcula como:

$$\text{head}_h = \text{softmax}\left(\frac{Q_h K_h^T}{\sqrt{d_h}}\right) V_h, \quad (4)$$

donde $Q_h = ZW_h^Q$, $K_h = ZW_h^K$ y $V_h = ZW_h^V$ son las proyecciones de consulta, clave y valor. Las salidas de las cabezas se concatenan y se proyectan para obtener una representación contextual de la huella RSSI. Esta operación permite que el modelo asigne mayor peso a fuentes de señal estables o discriminativas y reduzca la influencia de mediciones ruidosas, ambiguas o poco informativas.

El bloque se completa con normalización, conexiones residuales, una pequeña red feed-forward y regularización

mediante *dropout*. Para controlar la complejidad del modelo, se propone iniciar con una arquitectura compacta: una o dos capas de atención, dos o cuatro cabezas, dimensión de embedding reducida y clasificador denso final. Estos hiperparámetros se seleccionan en validación, ya que forman parte de la dimensión “complejidad del modelo” definida en la matriz.

IV-C. Clasificación y Localización

La representación contextual de la huella se agrega mediante promedio o atención de agrupamiento para obtener un vector u_i . Luego, una capa *softmax* estima la probabilidad de pertenencia a cada sector:

$$P(c|x_i) = \text{softmax}(W_c u_i + b_c), \quad (5)$$

y el sector estimado se define como:

$$\hat{c}_i = \arg \max_c P(c|x_i). \quad (6)$$

El entrenamiento se realiza minimizando entropía cruzada categórica:

$$\mathcal{L}_{CE} = - \sum_{c=1}^C y_{ic} \log P(c|x_i), \quad (7)$$

donde C es el número de sectores del escenario evaluado. Con el dataset disponible, C puede ser 28 para los archivos combinados, 7 para la primera planta o 21 para la planta baja. A partir del sector estimado se asigna el centroide correspondiente y se calcula el error métrico-espacial definido en la Sección V.

IV-D. Fusión RSSI–Orientación para Obra Observada

La contribución específica de este trabajo se ubica en la decisión contextual posterior a la clasificación de sector. Sea $\mathcal{O}$ el conjunto de obras, vitrinas o paneles de una sala. Cada obra o_k se registra con un sector asociado s_k y una dirección esperada de observación β_k medida en el plano de la sala. Para una muestra i , el puntaje contextual de una obra se define como:

$$S(o_k|i) = P(c = s_k|x_i^r) \cdot \exp(\kappa \cos(\theta_i - \beta_k)), \quad (8)$$

donde $P(c = s_k|x_i^r)$ representa la probabilidad de que el usuario se encuentre en el sector de la obra, θ_i es el rumbo del smartphone, β_k es la dirección esperada hacia la obra y κ controla cuánto peso recibe la coincidencia angular. Así, una obra ubicada en el sector correcto pero fuera de la dirección de observación recibe menor puntaje que una obra compatible con la posición y con el rumbo del dispositivo.

La obra activa se estima como:

$$\hat{o}_i = \arg \max_{o_k \in \mathcal{O}} S(o_k|i). \quad (9)$$

Esta formulación permite convertir el problema de localización en una tarea de mediación cultural: no basta con

predecir el sector, sino que se debe activar el contenido más pertinente para aquello que el visitante probablemente está mirando. En una implementación móvil, θ_i puede suavizarse con una ventana temporal corta para reducir cambios bruscos por movimientos de mano.

IV-E. Activación Contextual

Para vincular la localización con la pertinencia del servicio, se define una función $g(\hat{c}_i)$ que mapea cada sector estimado hacia una zona, sala u objeto de interés. La activación contextual se produce solo si la confianza del clasificador supera un umbral τ :

$$A_i = \begin{cases} g(\hat{c}_i), & \max_c P(c|x_i) \geq \tau, \\ \emptyset, & \max_c P(c|x_i) < \tau. \end{cases} \quad (10)$$

En la fase experimental actual, $g(\cdot)$ se evalúa como una regla simulada por sector o zona, debido a que el dataset no contiene recorridos reales ni eventos de una aplicación de museo. En la extensión RSSI–orientación, $g(\cdot)$ se reemplaza o complementa con el selector de obra de las ecuaciones 8 y 9. En esa fase, la aplicación móvil permitirá medir activaciones correctas, falsas y tardías con registros reales de uso. Así, el modelo queda alineado con las tres dimensiones de la matriz: predice sectores para evaluar exactitud, permite escenarios cruzados para medir robustez y entrega una decisión de activación para analizar pertinencia del servicio.

Tabla IV
COMPONENTES DEL MODELO PROPUESTO

Componente	Función en la investigación
Tokens RSSI	Representar cada beacon o punto Wi-Fi/BLE como fuente individual de información.
Máscara de señal	Permitir señales ausentes y extensión a infraestructura heterogénea.
Atención multi-cabeza	Ponderar fuentes relevantes y reducir influencia de RSSI ruidoso.
Orientación del smartphone	Representar dirección de observación mediante $\sin(\theta)$ y $\cos(\theta)$.
Clasificador <i>softmax</i>	Estimar la probabilidad de pertenencia a cada sector indoor.
Selector de obra	Combinar sector estimado y coincidencia angular para activar contenido contextual.

V. DESARROLLO EXPERIMENTAL Y RESULTADOS

El desarrollo experimental se ejecutó con el conjunto de datos ubicado en la ruta de repositorio BLE_RSSI_Indoor_Localization_Dataset/data/. Este contiene nueve archivos CSV: tres conjuntos combinados por potencia de transmisión (data/Tx_8.csv, data/Tx_4.csv y data/Tx0.csv), tres subconjuntos de primera planta (data/Tx_8A.csv, data/Tx_4A.csv y data/Tx0A.csv) y tres subconjuntos de planta baja (data/Tx_8B.csv, data/Tx_4B.csv y data/Tx0B.csv). Cada registro contiene seis características RSSI, denominadas B1–B6, y una etiqueta de sector. Los archivos combinados tienen 2800 muestras y 28 sectores; los archivos de primera planta tienen

700 muestras y 7 sectores; y los archivos de planta baja tienen 2100 muestras y 21 sectores. En todos los casos se verificó un balance de 100 muestras por sector.

La secuencia experimental replica la forma de validación cuantitativa del artículo de referencia, pero adaptada a clasificación de sectores. Primero se establecieron líneas base con algoritmos convencionales. Luego se entrenó el modelo con atención usando las mismas particiones en los conjuntos combinados de 28 sectores. Después se compararon exactitud, F1 macro, error espacial y estabilidad entre potencias. Finalmente, la predicción de sector se mantuvo como entrada para una regla de activación contextual, que conecta el experimento con el objeto de estudio de museos y espacios culturales.

V-A. Preparación de Datos

La preparación de datos considera cinco pasos. Primero, se verificaron duplicados, rangos RSSI y balance por sector. Segundo, se normalizaron las características B1–B6 mediante estandarización calculada solo con el conjunto de entrenamiento. Tercero, se codificó la etiqueta *Sector* como clase supervisada. Cuarto, se conservó la potencia de transmisión como atributo de escenario experimental, no como entrada directa del modelo en la comparación principal. Quinto, para estimar error métrico, se asignaron coordenadas aproximadas a los sectores según la geometría documentada: la primera planta se modeló como un corredor de 7 sectores y la planta baja como una grilla de 3 por 7 sectores. En los conjuntos combinados se agregó una penalización vertical de 3 m cuando la predicción cambió de planta. Esta asignación permitió convertir una predicción de sector en distancia euclidiana aproximada:

$$e_i = \sqrt{(x_i - \hat{x}_i)^2 + (y_i - \hat{y}_i)^2 + (3|f_i - \hat{f}_i|)^2}, \quad (11)$$

donde (x_i, y_i, f_i) representa el centroide y planta del sector real, y $(\hat{x}_i, \hat{y}_i, \hat{f}_i)$ el centroide y planta del sector predicho.

V-B. Escenarios de Evaluación

La Tabla V define los escenarios experimentales específicos. Los escenarios E1–E3 miden exactitud dentro de una misma potencia. E4 evalúa generalización entre potencias de transmisión. E5 y E6 separan la evaluación por planta para identificar diferencias entre el corredor de primera planta y la grilla de planta baja. E7 simula pertinencia del servicio al mapear sectores predichos a eventos de activación contextual. El escenario E8 no se ejecuta con el dataset público porque este no contiene orientación; se incluye como protocolo de prueba de concepto para capturar el aporte propio en una sala de museo con 6–8 sectores.

V-C. Modelos Comparados

La comparación ejecutada incluyó cuatro líneas base y el modelo de atención RSSI. Las líneas base fueron k vecinos más cercanos, Random Forest, Support Vector Machine con kernel RBF y una red neuronal multicapa. El modelo de

atención utiliza la entrada B1–B6, una capa de proyección, un bloque de atención multi-cabeza y una capa de clasificación *softmax*. Para una comparación justa, todos los modelos usaron las mismas particiones de entrenamiento y prueba. Los modelos clásicos se implementaron con *scikit-learn*; el modelo con atención se implementó en PyTorch y se ejecutó sobre GPU NVIDIA RTX 3050 cuando estuvo disponible. El modelo híbrido RSSI–orientación se mantiene como extensión a validar con el escenario E8, ya que requiere registrar θ_i y la obra realmente observada.

V-D. Partición y Validación

En los escenarios E1–E3 se usó validación cruzada estratificada de cinco particiones, manteniendo la proporción de muestras por sector. En E4 se usó validación cruzada entre dominios: entrenar con una potencia completa y probar con otra, sin mezclar registros del conjunto de prueba durante el entrenamiento. En E5 y E6 se repitió el procedimiento por planta para evaluar si la geometría del ambiente modifica la dificultad del problema. Esta separación evitó mezclar muestras equivalentes de un mismo sector en entrenamiento y prueba cuando el objetivo fue medir robustez ante cambio de potencia.

Para E8, el protocolo propuesto consiste en delimitar una sala con 6–8 sectores y asociar cada sector con una obra principal o zona de observación. Cada muestra debe registrar: marca temporal, sector real, obra real observada, valores RSSI, azimut del smartphone, inclinación opcional, identificador de dispositivo y evento de activación. La comparación debe realizarse entre tres variantes: RSSI solo, RSSI más orientación por fusión temprana y RSSI más orientación por selector contextual. Esta estructura permite medir si la dirección del celular mejora la obra activada, incluso cuando la clasificación de sector se mantiene igual.

V-E. Criterios de Evaluación

La exactitud métrico-espacial se evalúa con accuracy, F1 macro, matriz de confusión, error medio en metros y RMSE. La robustez del sistema se mide mediante la degradación relativa entre escenarios:

$$D = \frac{M_{\text{base}} - M_{\text{prueba}}}{M_{\text{base}}} \times 100, \quad (12)$$

donde M_{base} es el rendimiento dentro de la misma potencia y M_{prueba} el rendimiento al probar en otra potencia o planta. La pertinencia del servicio se calcula a partir de reglas de activación por sector: una activación es correcta si el sector predicho pertenece a la misma zona contextual que el sector real; es falsa si activa una zona incorrecta; y es tardía si el modelo requiere más de un umbral de inferencia definido para entregar la respuesta. En esta primera fase, la activación tardía se estima con el tiempo de inferencia del modelo, no con recorridos reales de usuarios.

Las Tablas VI y VII muestran que Random Forest obtuvo el mejor desempeño dentro de cada potencia. La primera planta fue menos compleja por tener 7 sectores y una

Tabla V
 ESCENARIOS EXPERIMENTALES EJECUTADOS Y EXTENSIÓN RSSI–ORIENTACIÓN

Esc.	Archivos	Objetivo	Métricas principales
E1	data/Tx_8.csv	Clasificación de 28 sectores con potencia -8 dBm	Accuracy, F1 macro, RMSE, error medio
E2	data/Tx_4.csv	Clasificación de 28 sectores con potencia -4 dBm	Accuracy, F1 macro, RMSE, error medio
E3	data/Tx0.csv	Clasificación de 28 sectores con potencia 0 dBm	Accuracy, F1 macro, RMSE, error medio
E4	data/Tx_*.csv	Robustez ante cambio de potencia: entrenar en una potencia y probar en otra	Degradación de accuracy, F1 macro, error medio por potencia
E5	data/Tx_*A.csv	Evaluación en primera planta, 7 sectores	Accuracy, F1 macro, matriz de confusión
E6	data/Tx_*B.csv	Evaluación en planta baja, 21 sectores	Accuracy, F1 macro, matriz de confusión
E7	data/Tx_*.csv y subconjuntos A/B	Pertinencia del servicio por activación correcta de zona	Tasa de activación correcta, activación falsa, activación tardía simulada
E8	Captura propia en sala con 6–8 sectores	Prueba de concepto RSSI–orientación para seleccionar obra observada	Accuracy de sector, accuracy de obra, error angular, falsas activaciones, latencia móvil

Tabla VI
 RESULTADOS DE VALIDACIÓN CRUZADA EN LOS CONJUNTOS COMBINADOS DE 28 SECTORES

Tx	Mejor modelo	Accuracy	F1 macro	Error medio	RMSE	Acc. atención
-8 dBm	Random Forest	62.14 %	61.35 %	1.221 m	2.175 m	42.93 %
-4 dBm	Random Forest	56.46 %	55.59 %	1.294 m	2.187 m	43.11 %
0 dBm	Random Forest	57.14 %	56.43 %	1.329 m	2.232 m	42.14 %

Tabla VII
 MEJOR DESEMPEÑO POR PLANTA CON VALIDACIÓN CRUZADA ESTRATIFICADA

Tx	Planta A acc.	Planta A F1	Planta A error	Planta B acc.	Planta B F1	Planta B error
-8 dBm	73.14 %	72.51 %	0.551 m	65.95 %	65.27 %	1.069 m
-4 dBm	70.29 %	69.90 %	0.542 m	56.62 %	55.34 %	1.253 m
0 dBm	66.29 %	66.05 %	0.722 m	59.10 %	58.52 %	1.271 m

Tabla VIII
 ROBUSTEZ CRUZADA ENTRE POTENCIAS EN 28 SECTORES

Modelo	Acc.	F1	Error	RMSE
MLP	26.38 %	23.60 %	2.361 m	3.034 m
SVM-RBF	25.01 %	23.19 %	2.409 m	3.077 m
KNN	23.92 %	22.42 %	2.487 m	3.153 m
Random Forest	23.12 %	21.38 %	2.524 m	3.184 m
Atención	22.34 %	19.28 %	2.484 m	3.088 m

Tabla IX
 SIMULACIÓN CONTROLADA RSSI–ORIENTACIÓN EN SALA PROXY DE 7 SECTORES

Tx	RSSI solo	RSSI+orient.	Mejora
-8 dBm	73.43 %	84.57 %	+11.14 pp
-4 dBm	71.00 %	81.14 %	+10.14 pp
0 dBm	67.00 %	81.29 %	+14.29 pp
Prom.	70.48 %	82.33 %	+11.86 pp

geometría tipo corredor; por ello alcanzó hasta 73.14 % de exactitud. La planta baja, con 21 sectores distribuidos en una grilla, presentó mayor dificultad y errores medios superiores a 1 m. En los conjuntos combinados de 28 sectores, el mejor resultado fue 62.14 % con -8 dBm. El modelo de atención, en su configuración inicial, no superó a las líneas base clásicas y se mantuvo alrededor de 42–43 % de exactitud.

La Tabla VIII evidencia que el cambio de potencia genera una degradación severa. Al entrenar con una potencia y probar con otra, las exactitudes promedio se ubicaron entre 22.34 % y 26.38 %. Este resultado confirma que la potencia de transmisión introduce un desplazamiento de dominio relevante y que el modelo final deberá incorporar calibración, aumento de datos o entrenamiento multi-dominio para sostener la robustez exigida por la matriz de investigación. El escenario E7 se mantiene como evaluación funcional simulada, debido a que el dataset no contiene recorridos reales ni eventos de una aplicación de museo.

La Tabla IX resume una simulación controlada del escenario E8 usando la primera planta como sala proxy de siete sectores. Se generó una orientación sintética centrada en la obra real con ruido angular de 30° y se combinó con las probabilidades de Random Forest mediante el selector contextual de la ecuación 8. Bajo ese supuesto moderado, la activación basada en RSSI–orientación elevó el promedio de 70.48 % a 82.33 %. Este resultado no constituye validación de campo; se reporta como análisis de sensibilidad que justifica capturar orientación real en una prueba de concepto.

VI. DISCUSIÓN

La experimentación permite articular el problema de localización indoor con el uso real de dispositivos Wi-Fi/BLE diversos en museos y espacios culturales. La exactitud métrico-

espacial mide la cercanía entre ubicación estimada y ubicación real; la robustez del sistema evalúa si el modelo sostiene su desempeño bajo variaciones de señal y dispositivo; y la pertinencia del servicio vincula la inferencia de ubicación con la activación contextual que recibe el visitante. En este punto se ubica el aporte propio del trabajo: pasar de una predicción de sector basada solo en RSSI a una decisión contextual que también considera la orientación del smartphone.

Los resultados muestran que las líneas base clásicas, especialmente Random Forest, capturan mejor la estructura tabular del dataset en esta etapa. El modelo de atención sigue siendo metodológicamente pertinente para estudiar ponderaciones dependientes de la entrada, pero su configuración inicial no fue suficiente para superar a los clasificadores convencionales. En cambio, la simulación RSSI–orientación sugiere que la dirección del smartphone puede aportar más valor en la decisión de obra observada que en la clasificación RSSI pura. Esta diferencia refuerza que el aporte del trabajo no debe medirse solo como mejora del clasificador, sino como mejora de la activación contextual.

La principal limitación de la fase inicial es que el conjunto de datos disponible corresponde a BLE, a un único receptor y a RSSI sin orientación. Además, las pruebas cruzadas entre potencias evidencian un desplazamiento de dominio importante: entrenar con una potencia y probar con otra redujo el rendimiento a valores cercanos al 25 %. Por ello, los resultados deben interpretarse como una validación experimental preliminar y como una línea base reproducible. La propuesta RSSI–orientación no pretende corregir todos los errores de radiofrecuencia, sino mejorar la pertinencia de activación cuando el sector estimado no basta para decidir qué obra observa el visitante. Para responder plenamente al objeto de estudio, se requiere incorporar datos Wi-Fi, múltiples dispositivos, orientación del smartphone, calibración entre potencias y eventos reales o simulados de activación en un entorno cultural.

VII. CONCLUSIONES

Este artículo reconstruye y ejecuta una primera fase experimental de la propuesta de investigación sobre precisión de localización indoor de dispositivos Wi-Fi/BLE diversos en museos y espacios culturales. A diferencia de una simple reproducción de un dataset público, el estudio reformula el problema hacia un modelo híbrido RSSI–orientación con mecanismos de atención, donde la localización por sector se complementa con la dirección del smartphone para activar contenido de la obra probablemente observada.

El enfoque integra fingerprinting RSSI, comparación con líneas base de aprendizaje automático, análisis cuasiexperimental transversal y vinculación con eventos de activación contextual. En el dataset BLE evaluado, Random Forest obtuvo el mejor desempeño dentro de potencia, con hasta 62.14 % de exactitud en 28 sectores y 73.14 % en la primera planta. En la simulación controlada de sala proxy, la fusión RSSI–orientación elevó la activación promedio de 70.48 % a 82.33 %, lo que sugiere un potencial de mejora de 11.86

puntos porcentuales bajo supuestos de orientación moderadamente ruidosa. La validación final deberá realizarse en una sala de museo con 6–8 sectores, registro de RSSI, orientación del smartphone y eventos de activación por obra.

DISPONIBILIDAD DE DATOS Y CÓDIGO FUENTE

Los datos BLE utilizados como base experimental inicial correspondieron al repositorio fuente `BLE_RSSI_Indoor_Localization_Dataset/`. Las rutas de reproducibilidad se expresan desde esa raíz: `data/` para los archivos CSV, `metadata/` para el diccionario de variables y metadatos de sectores/beacons, `images/` para mapas y fotografías del entorno, `Notebooks/` para cuadernos de análisis y documentación/technical_report_environment.pdf para el informe técnico. En la copia local usada para compilar este manuscrito, dicha raíz corresponde a `/home/eduardo/proyectos/publicacion/dataset/`. El código reproducible de esta etapa se encuentra en `scripts/run_indoor_experiments.py`; sus dependencias se listan en `requirements-experimentos.txt`; y los resultados generados se almacenan en `results/with_in_power_summary.csv`, `results/cross_power_summary.csv` y archivos CSV complementarios. La simulación de sensibilidad RSSI–orientación se encuentra en `scripts/run_orientation_sensitivity.py`, con resultados en `results/orientation_sensitivity_summary.csv` y `results/orientation_sensitivity_details.csv`. Los datos de orientación real del smartphone y obra observada no forman parte del dataset público; deberán generarse en la prueba de concepto E8.

USO DE INTELIGENCIA ARTIFICIAL

Se utilizó asistencia de inteligencia artificial generativa como apoyo en la organización del manuscrito, revisión de coherencia metodológica, redacción académica, adecuación a formato $\LaTeX$ y depuración de compilación. La IA no fue empleada para fabricar datos, alterar resultados experimentales ni reemplazar la revisión académica de los autores. El contenido final, las decisiones metodológicas y la responsabilidad sobre el manuscrito corresponden a los autores.

CONTRIBUCIONES DE AUTORÍA

Jhonor Eduardo Guevara Lázaro: conceptualización, sistematización de la matriz de consistencia, revisión bibliográfica, planteamiento metodológico, definición del modelo híbrido RSSI–orientación, curación y organización del dataset, diseño y ejecución experimental de la línea base RSSI, análisis de resultados, redacción del borrador, edición del manuscrito y preparación del documento en $\LaTeX$.

Yury Tello Canchapoma: supervisión académica, asesoría metodológica, revisión crítica del enfoque experimental, orientación sobre estructura del artículo, revisión editorial y validación general del manuscrito.

REFERENCIAS

- [1] V. Bellavista-Parent, J. Torres-Sospedra, and A. Perez-Navarro, "New trends in indoor positioning based on WiFi and machine learning: A systematic review," in *2021 International Conference on Indoor Positioning and Indoor Navigation (IPIN)*, 2021, doi: <https://doi.org/10.1109/IPIN51156.2021.9662521>.
- [2] A. Gerez, O. E. Goñi, and L. Leiva, "Aumento de precisión en localización indoor basado en redes neuronales," *Revista Elektron*, vol. 4, no. 2, pp. 74–80, 2020, doi: <https://doi.org/10.37537/rev.elektron.4.2.114.2020>.
- [3] M. Teran, H. Carrillo, and C. Parra, "WLAN-BLE based indoor positioning system using machine learning cloud services," in *2017 2nd International Conference on Frontiers of Sensors Technologies*, 2017.
- [4] A. Ferrero-Lopez, A. J. Gallego, and M. A. Lozano, "Bluetooth low energy indoor positioning: A fingerprinting neural network approach," *Internet of Things*, vol. 31, p. 101565, 2025, doi: <https://doi.org/10.1016/j.iot.2025.101565>.
- [5] P. Supanakoon and S. Promwong, "Evaluation of distance error with bluetooth low energy transmission model for indoor positioning," *Journal of Mobile Multimedia*, vol. 17, no. 4, pp. 707–722, 2021, doi: <https://doi.org/10.13052/jmm1550-4646.17411>.
- [6] K. Phutcharoen, M. Chamchoy, and P. Supanakoon, "Accuracy study of indoor positioning with bluetooth low energy beacons," in *2020 Joint International Conference on Digital Arts, Media and Technology with ECTI Northern Section Conference on Electrical, Electronics, Computer and Telecommunications Engineering*, 2020.
- [7] A. H. Salamah, M. Tamazin, M. A. Sharkas, and M. Khedr, "An enhanced WiFi indoor localization system based on machine learning," in *International Conference on Indoor Positioning and Indoor Navigation (IPIN)*, 2016.
- [8] K. Park, Y. Lee, S. Seo, M. J. Kim, G. Lee, D. Yoon, and J. Yoo, "Study on WiFi-based indoor positioning prediction using machine learning techniques," in *2023 14th International Conference on Information and Communication Technology Convergence (ICTC)*, 2023, doi: <https://doi.org/10.1109/ICTC58733.2023.10393117>.
- [9] S. Tiku, D. Gufran, and S. Pasricha, "Multi-head attention neural network for smartphone invariant indoor localization," in *International Conference on Indoor Positioning and Indoor Navigation (IPIN)*, 2022, doi: <https://doi.org/10.1109/IPIN54987.2022.9918120>.
- [10] D. Gufran, S. Tiku, and S. Pasricha, "STELLAR: Siamese multiheaded attention neural networks for overcoming temporal variations and device heterogeneity with indoor localization," *IEEE Journal of Indoor and Seamless Positioning and Navigation*, vol. 1, pp. 115–128, 2023, doi: <https://doi.org/10.1109/JISPIN.2023.3334693>.
- [11] J. Li, M. Guo, and S. Li, "An indoor localization system by fusing smartphone inertial sensors and bluetooth low energy beacons," in *2017 2nd International Conference on Frontiers of Sensors Technologies*, 2017.
- [12] J. Xia, Y. Wang, B. Jiang, and G. Xiong, "Research on indoor positioning system based on BLE-AOA/UWB technology," in *Proceedings of the 41st Chinese Control Conference*, 2022.
- [13] S. Xu, R. Chen, G. Guo, Z. Li, L. Qian, F. Ye, Z. Liu, and L. Huang, "Bluetooth, floor-plan, and microelectromechanical systems-assisted wide-area audio indoor localization system: Apply to smartphones," *IEEE Transactions on Industrial Electronics*, 2021, doi: <https://doi.org/10.1109/TIE.2021.3111561>.
- [14] I. Yaman, G. Tian, E. Tegler, J. Gulin, N. Challa, F. Tufvesson, O. Edfors, K. Astrom, S. Malkowsky, and L. Liu, "LuViRA dataset validation and discussion: Comparing vision, radio, and audio sensors for indoor localization," *IEEE Journal of Indoor and Seamless Positioning and Navigation*, vol. 2, pp. 240–252, 2024, doi: <https://doi.org/10.1109/JISPIN.2024.3429110>.
- [15] Y. Tsuchiya, N. Suga, K. Uruma, and M. Fujisawa, "Integration of CSI and camera image for indoor wireless localization," in *IEEE Access*, 2026, doi: <https://doi.org/10.1109/ACCESS.2026.3678610>.
- [16] J. Liu, Z. Yang, S. Li, S. Zlatanova, B. Yang, G. Li, B. Yu, and Q. Zhang, "MMVP: Multiscene indoor localization for smartphones by using collaborative visual localization and multisensor fusion," *IEEE Internet of Things Journal*, 2026, doi: <https://doi.org/10.1109/JIOT.2026.3657167>.
- [17] M. Choi, W.-K. Park, and I. Lee, "Smart office energy-saving service using bluetooth low energy beacons and smart plugs," in *2015 IEEE International Conference on Data Science and Data Intensive Systems*, 2015, doi: <https://doi.org/10.1109/DSDIS.2015.69>.
- [18] Android Developers, "Position sensors," https://developer.android.com/develop/sensors-and-location/sensors/sensors_position, 2026, accedido: 24 de junio de 2026.
- [19] J. C. Aguilar Herrera, P. G. Ploeger, A. Hinkenjann, J. Maiero, M. Flores, and A. Ramos, "Pedestrian indoor positioning using smartphone multi-sensing, radio beacons, user positions probability map and IndoorOSM floor plan representation," in *International Conference on Indoor Positioning and Indoor Navigation (IPIN)*, 2014.
- [20] J. Zhang, J. Sun, H. Wang, W. Xiao, and L. Tan, "Large-scale WiFi indoor localization via extreme learning machine," in *Proceedings of the 36th Chinese Control Conference*, 2017.
- [21] T.-M. Dinh and N.-S. Duong, "Smartphone indoor positioning system based on BLE i beacon and reliable region-based position correction algorithm," in *2019 International Conference on Advanced Technologies for Communications (ATC)*, 2019.
- [22] A. Singampalli, G. R. R. Sri Lakshmi, and S. Pasricha, "xKAN: Explainable AI for smartphone based indoor localization using Wi-Fi fingerprinting," *IEEE Access*, 2026.